# EDA de Sobrevivência com Riscos Competitivos: Óbito Fetal vs Nascimento Vivo — SP (2018–2023)

## Contents


**1. Variáveis do conjunto de dados** **2**

**2. Pacotes** **3**

**3. Padronização de faltantes e coerções** **4**

**4. Diagnóstico de faltantes** **7**

**5. Recodificações principais e criação de objetos de tempo/evento** **14**

**6. Descrição básica** **15**

**6.1 Kaplan–Meier (KM) sob as duas perspectivas** **18**

**7. KM de cada caso** **20**

Sexo . . . 20
Ano . . . 22
Pandemia . . . 24
Idade da mãe . . . 26
Peso . . . 28
Parto . . . 30
Faixas de gestação . . . 32
escmae (escolaridade da mãe) . . . 34
Local de ocorrência . . . 36
Tipo de gravidez (níveis originais) . . . 38
Tipo de gravidez (Única vs Múltipla) . . . 40
qtdfilvivo (Número de filhos vivos) e qtdfilmort (Número de filhos mortos) . . . 42

**Comentários** **47**


knitr::opts_chunk$set(echo = FALSE, message = FALSE, include = FALSE, , results='hide', warning = FALSE, fig.width = 8, fig.height = 5, dpi = 300) set.seed(123) options(scipen = 999)

# 1. Variáveis do conjunto de dados

- `cod_cep` - ~
- `codestab` - Código do estabelecimento de saúde
- `origem` - Origem do registro
- `codmunnatu`
  - SINASC: código do município de naturalidade da mãe;
  - SIM: código do município de naturalidade do falecido (o equivalente no SINASC é a variável CODUFNATU)
  - Obs: nome da variável é a mesma, mas as informações são diferentes.
- `sexo` - ~
- `racacor` - ~
- `codmunres` - Código do município de residência (em caso de óbito fetal, considera o município de residência da mãe)
- `idademae` - Idade da mãe
- `escmae` - Escolaridade da mãe em anos
- `escmae2010` - Escolaridade 2010. Nível da última série concluída pela mãe
- `qtdfilvivo` - Número de filhos vivos
- `qtdfilmort` - Número de filhos mortos
- `gravidez` - Tipo de gravidez
- `semagestac` - Número de semanas de gestação
- `gestacao` - Faixas de semanas de gestação
- `parto` - Tipo de parto
- `peso` - Peso ao nascer em gramas
- `numerolote` - Número do lote
- `dtcadastro` - Data do cadastro do nascimento / óbito
- `versaosist` - Versão do sistema
- `dtrecebim` - Data do último recebimento do lote
- `escmaeagr1` - Escolaridade da mãe agregada (formulário a partir de 2010)
- `difdata`
  - SINASC: Diferença entre a data de Nascimento e data do recebimento original da DN ([DTNASC] – [DTRECORIGA])
  - SIM: Diferença entre a data de óbito e data do recebimento original da DO ([DTOBITO] – [DTRECORIGA)
- `contador` - Número identificador do registro
- `codmunocornasc`
  - SINASC: Código do município de nascimento
  - SIM: Código do município onde ocorreu o óbito
- `lococornasc`
  - SINASC: Local de nascimento
  - SIM: Local de ocorrência do óbito
- `horaobitonasc`
  - SINASC: Horário de nascimento
  - SIM: Horário do óbito
- `ocupmaecodocupmae`
  - SINASC: Código de ocupação da mãe conforme tabela do CBO (Código Brasileiro de Ocupações)
  - SIM: Tipo de trabalho exercido habitualmente pela Mãe, de acordo com Classificação Brasileira de Ocupações – CBO 2002. No caso da mãe do falecido(a) ser "aposentada", preencher com a ocupação habitual anterior
- `codmunnatucodufnatu`
  - SINASC: código UF de naturalidade
  - SIM: Código do município e UF de naturalidade do falecido
  - Obs: a variável CODUFNATU apresenta apenas o código da UF, enquanto CODMUNNATU apresenta tanto UF quanto município
- `ano` - 2018 - 2022
- `evento` - 0 = nascido vivo, 1 = óbito fetal
- `pandemia` - 1 = 2020 ou 2021, 0 = os demais anos
- `latitude` - latitude do estabelecimento de saúde do caso
- `longitude` - longitude do estabelecimento de saúde do caso
- `uf` - SP

Para mais detalhes, conferir a planilha: PLANILHA

## 2. Pacotes

```r
# Setup global
options(scipen = 999)
set.seed(123)

# Instala e carrega pacotes
pkg <- function(x){
  if (!requireNamespace(x, quietly = TRUE)) install.packages(x, dep = TRUE)
  suppressPackageStartupMessages(library(x, character.only = TRUE))
}

lapply(c("tidyverse","data.table","janitor","stringr","forcats","readxl",
         "survival","survminer","cmprsk","muhaz","Matrix","viridis",
         "naniar","visdat","skimr", "purrr"), pkg)
```

```r
# Carregamento
cat("=== ETAPA 1: CARREGAMENTO DOS DADOS ===\n")
```

```
## === ETAPA 1: CARREGAMENTO DOS DADOS ===
```

```r
# dataset_combined_df gerado em load_data.Rmd
dados_sp <- readRDS("dataset_combined_df.rds")

dim(dados_sp)
```

```
## [1] 3321567      31
```

```r
dplyr::glimpse(dados_sp, width = 80)
```

```
## Rows: 3,321,567
## Columns: 31
## $ codmunnatucodufnatu <chr> "355220", "355220", NA, NA, "350000", NA, "350000"~
## $ sexo                <chr> "2", "2", "2", "2", "2", "1", "1", "0", "1", "2", ~
## $ racacor             <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA~
## $ codmunres           <chr> "355220", "355220", "355030", "351630", "351640", ~
## $ codestab            <chr> "2708779", "2708566", NA, "3028399", "7580770", "3~
## $ idademae            <chr> NA, "26", NA, "19", "38", "30", "41", "27", NA, "1~
## $ escmae              <chr> NA, "4", NA, "5", "3", NA, "3", "4", NA, "4", "5",~
## $ escmae2010          <chr> NA, "3", NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
## $ qtdfilvivo          <chr> "99", "00", NA, "00", "00", NA, "03", "01", NA, "0~
## $ qtdfilmort          <chr> "99", "00", NA, "00", "00", NA, "00", "00", NA, "0~
## $ gravidez            <chr> "1", "2", NA, "1", "1", "1", "1", "1", NA, "1", "1~
## $ semagestac          <chr> "23", "30", NA, NA, NA, NA, NA, NA, NA, NA, NA, NA~
## $ gestacao            <chr> "2", "3", NA, "3", "5", "3", "4", "1", NA, "3", "3~
## $ parto               <chr> "1", "2", NA, "1", "1", NA, "1", "1", NA, "1", "1"~
## $ peso                <chr> "0610", "3540", NA, "1390", "3650", "0780", "1900"~
## $ numerolote          <chr> "20190010", "20180024", "20180007", "20180017", "2~
## $ dtcadastro          <chr> "13042018", "23052018", "19022018", "28042018", "0~
## $ versaosist          <chr> "3.2.00", "3.2.00", "3.2.01", "3.2.00", "3.2.00", ~
## $ dtrecebim           <chr> "07032019", "13062018", "21022018", "03052018", "0~
## $ escmaeagr1          <chr> NA, "06", NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, ~
## $ difdata             <chr> "332", "056", "049", "012", "013", "017", "020", "~
## $ contador            <chr> "1316722", "1316725", "1316726", "1316730", "13167~
## $ codmunocornasc      <chr> "355220", "355220", "355030", "351630", "350900", ~
## $ lococornasc         <chr> "1", "1", "3", "1", "1", "1", "1", "1", "1", "1", ~
## $ horaobitonasc       <chr> "0459", "1249", "0600", "0531", "1302", "0130", "1~
## $ ocupmaecodocupmae   <chr> "999992", "521110", NA, "421125", "999992", "99999~
```

```
## $ uf_ocor             <chr> "SP", "SP", "SP", "SP", "SP", "SP", "SP", "SP", "S~
## $ uf_resid            <chr> "SP", "SP", "SP", "SP", "SP", "SP", "SP", "SP", "S~
## $ ano                 <dbl> 2018, 2018, 2018, 2018, 2018, 2018, 2018, 2018, 20~
## $ evento              <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,~
## $ pandemia            <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,~
```

## 3. Padronização de faltantes e coerções

```r
# Limpeza de faltantes e coerções

# Ignorado está como "0"
dados_sp$sexo <- ifelse(dados_sp$sexo == "0", "9", dados_sp$sexo)

# 743 casos com 99 filhos
dados_sp <- filter(dados_sp, dados_sp$qtdfilvivo != 99)

# 254 casos com 99 filhos
dados_sp <- filter(dados_sp, dados_sp$qtdfilmort != 99)

# 379 casos em semana gestacional 99
dados_sp <- filter(dados_sp, dados_sp$semagestac != 99)

# Ignorado está como "09"
dados_sp$escmaeagr1 <- ifelse(dados_sp$escmaeagr1 == "09", "9", dados_sp$escmaeagr1)

# Vars onde "9/99/999..." = Ignorado (baseado nos dicionários)
vars_ignorado <- intersect(c("escmae","escmae2010","racacor", "escmae", "gravidez",
                             "gestacao","parto","lococornasc", "sexo"),
                           names(dados_sp))

# Função: limpa espaços e troca "" e " " por NA
clean_blank <- function(x){
  if (is.character(x)) {
    x <- stringr::str_squish(x)
    x[x %in% c("", " ")] <- NA_character_
  }
  x
}

# Função que em variáveis elegíveis, troca "9+", "99+", "999+", etc... por NA
as_na_ignorado <- function(x){
  if (is.character(x)) {
    x[grepl("^9+$", x)] <- NA_character_
  }
  x
}

dados_sp_cln <- dados_sp %>%
  mutate(across(where(is.character), clean_blank)) %>%
  mutate(across(all_of(vars_ignorado), as_na_ignorado)) %>%
  # Coerções numéricas
  mutate(
    semagestac = suppressWarnings(as.numeric(semagestac)),
    idademae   = suppressWarnings(as.numeric(idademae)),
    peso       = suppressWarnings(as.numeric(peso)),
```

```r
    ano        = suppressWarnings(as.integer(ano)),
    evento     = suppressWarnings(as.integer(evento)),
    pandemia   = suppressWarnings(as.integer(pandemia))
  )

#-------------- Definições de intervalos
rng_sem   <- c(0, 45)     # semanas gestacionais plausíveis
rng_idade <- c(10, 49)    # idade materna plausível
peso_max  <- 7000
n0 <- nrow(dados_sp_cln)

# Flags simples para sem/idade (NA passa)
in_sem   <- dplyr::between(dados_sp_cln$semagestac,
                           rng_sem[1],
                           rng_sem[2]) | is.na(dados_sp_cln$semagestac)
in_idade <- dplyr::between(dados_sp_cln$idademae,
                           rng_idade[1],
                           rng_idade[2]) | is.na(dados_sp_cln$idademae)

# ------------------------ Aqui estou tentando usar a lógica dada no manual
# de instruções da declaração de óbito, que caracteriza, também, óbito fetal
# quando semana gestacional menor que 20, mas que o peso seja maior que 500g
# (ver sessão de comentário ao final do arquivo)

# Regra condicional para variável peso
#    - Mantém NA como TRUE.
#    - Garante teto de coerência (<= peso_max) quando peso não for NA.
peso_ok <- with(dados_sp_cln, {
  # normaliza evento para 0,1 e NA
  ev <- ifelse(evento %in% c(0L, 1L), evento, NA_integer_)
  sg <- semagestac
  pw <- peso

  cond <- rep(TRUE, length(pw))  # default: passa (NA tratado adiante)

  # onde peso não é NA, aplica regras
  idx_non_na <- !is.na(pw)
  if (any(idx_non_na)) {
    cond[idx_non_na] <- FALSE  # zera e vamos ligar situação a situação

    # limites superiores coerentes (sempre exigidos quando há peso)
    teto <- pw[idx_non_na] <= peso_max

    # casos com evento == 1 (óbito fetal)
    idx_fd <- idx_non_na & ev == 1L
    if (any(idx_fd, na.rm = TRUE)) {
      # a) semagestac <= 20: peso > 500
      idx_a <- idx_fd & !is.na(sg) & sg <= 20
      cond[idx_a] <- (pw[idx_a] > 500) & teto[idx_non_na][which(idx_a[idx_non_na])]

      # b) semagestac > 20: peso > 0
      idx_b <- idx_fd & !is.na(sg) & sg > 20
      cond[idx_b] <- (pw[idx_b] > 0) & teto[idx_non_na][which(idx_b[idx_non_na])]

      # c) se semagestac for NA quando evento==1, deixa passar (não decide aqui)
```

```r
      idx_c <- idx_fd & is.na(sg)
      cond[idx_c] <- TRUE
    }

    # casos com evento == 0 (nascido vivo): peso > 0
    idx_lv <- idx_non_na & ev == 0L
    if (any(idx_lv, na.rm = TRUE)) {
      cond[idx_lv] <- (pw[idx_lv] > 0) & teto[idx_non_na][which(idx_lv[idx_non_na])]
    }

    # evento NA (ou outro valor): não removemos aqui
    idx_ev_na <- idx_non_na & is.na(ev)
    cond[idx_ev_na] <- TRUE
  }

  # por fim, se peso é NA, mantém TRUE
  cond[is.na(pw)] <- TRUE
  cond
})

# Contagens de "fora" (não-NA) para relatório
n_out_sem   <- sum(!is.na(dados_sp_cln$semagestac) & !dplyr::between(dados_sp_cln$semagestac,
                                                                     rng_sem[1],
                                                                     rng_sem[2]))
n_out_idade <- sum(!is.na(dados_sp_cln$idademae)   & !dplyr::between(dados_sp_cln$idademae,
                                                                     rng_idade[1],
                                                                     rng_idade[2]))

# Para peso, contamos somente onde há informação suficiente para aplicar a regra
tem_peso      <- !is.na(dados_sp_cln$peso)
peso_invalido <- tem_peso & !peso_ok
n_out_peso    <- sum(peso_invalido, na.rm = TRUE)

cat("Outliers detectados (não-NA) com novas regras:\n",
    sprintf(" - semagestac fora [%d,%d]: %d\n", rng_sem[1], rng_sem[2], n_out_sem),
    sprintf(" - idademae   fora [%d,%d]: %d\n", rng_idade[1], rng_idade[2], n_out_idade),
    sprintf(" - peso condicional inválido: %d\n", n_out_peso),
    sep = "")
```

```
## Outliers detectados (não-NA) com novas regras:
##  - semagestac fora [0,45]: 0
##  - idademae   fora [10,49]: 645
##  - peso condicional inválido: 825
```

```r
# Remoção efetiva (mantém NA): precisa estar dentro das faixas e com peso_ok
dados_sp_cln <- dados_sp_cln %>%
  dplyr::filter(in_sem, in_idade, peso_ok)

n1 <- nrow(dados_sp_cln)
cat(sprintf("Linhas antes: %d | depois da remoção: %d | removidas: %d (%.3f%%)\n",
            n0, n1, n0 - n1, 100*(n0 - n1)/n0))
```

```
## Linhas antes: 3297197 | depois da remoção: 3294871 | removidas: 2326 (0.071%)
```

```r
# Verificação pós-limpeza (ignorando NAs)
if (sum(!is.na(dados_sp_cln$semagestac)) > 0) {
```

```r
  stopifnot(max(dados_sp_cln$semagestac, na.rm = TRUE) <= rng_sem[2])
  stopifnot(min(dados_sp_cln$semagestac, na.rm = TRUE) >= rng_sem[1])
}
if (sum(!is.na(dados_sp_cln$idademae)) > 0) {
  stopifnot(max(dados_sp_cln$idademae, na.rm = TRUE) <= rng_idade[2])
  stopifnot(min(dados_sp_cln$idademae, na.rm = TRUE) >= rng_idade[1])
}

# Para peso, como há regra condicional, checamos apenas coerência superior quando peso não é NA
if (sum(!is.na(dados_sp_cln$peso)) > 0) {
  stopifnot(max(dados_sp_cln$peso, na.rm = TRUE) <= peso_max)
}

cat(sprintf("Faixas após limpeza (ignorando NAs):\n - semagestac: [%s, %s]\n - idademae: [%s, %s]\n",
            suppressWarnings(min(dados_sp_cln$semagestac, na.rm=TRUE)),
            suppressWarnings(max(dados_sp_cln$semagestac, na.rm=TRUE)),
            suppressWarnings(min(dados_sp_cln$idademae,   na.rm=TRUE)),
            suppressWarnings(max(dados_sp_cln$idademae,   na.rm=TRUE))))
```

```
## Faixas após limpeza (ignorando NAs):
##  - semagestac: [0, 45]
##  - idademae: [10, 49]
```

## 4. Diagnóstico de faltantes

```r
# Plano de variáveis (talvez façam sentido, mas nem todas)

vars_all <- c("codestab","sexo","racacor",
              "codmunres","idademae","escmae","escmae2010","qtdfilvivo","qtdfilmort",
              "gravidez","semagestac","gestacao","parto","peso","numerolote",
              "dtcadastro","versaosist","dtrecebim","escmaeagr1","difdata","contador",
              "codmunocornasc","lococornasc","horaobitonasc","ocupmaecodocupmae",
              "codmunnatucodufnatu","ano","evento","pandemia", "uf_ocor", "uf_resid")

present <- intersect(vars_all, names(dados_sp))

# Função geral de contagem de NA pós-limpeza
miss_summ <- function(df){
  tibble(
    variavel = names(df),
    n_na     = sapply(df, function(x) sum(is.na(x))),
    prop_na  = round(n_na / nrow(df), 4),
    n_unique = sapply(df, function(x) length(unique(x)))
  ) %>% arrange(desc(prop_na))
}

miss_tbl <- miss_summ(dados_sp_cln)

knitr::kable(head(miss_tbl, 20),
             caption = "Top 20 variáveis por proporção de faltantes (após padronização)")
```

Table 1: Top 20 variáveis por proporção de faltantes (após padronização)

| variavel | n_na | prop_na | n_unique |
|---|---|---|---|
| ocupmaecodocupmae | 244275 | 0.0741 | 2035 |
| codmunnatucodufnatu | 52085 | 0.0158 | 385 |
| racacor | 38042 | 0.0115 | 6 |
| codestab | 16583 | 0.0050 | 1399 |
| escmae2010 | 9357 | 0.0028 | 7 |
| escmae | 7911 | 0.0024 | 6 |
| escmaeagr1 | 5258 | 0.0016 | 14 |
| horaobitonasc | 1633 | 0.0005 | 1442 |
| dtrecebim | 1188 | 0.0004 | 1592 |
| sexo | 1040 | 0.0003 | 3 |
| idademae | 848 | 0.0003 | 41 |
| peso | 851 | 0.0003 | 4607 |
| gravidez | 544 | 0.0002 | 4 |
| parto | 631 | 0.0002 | 3 |
| codmunres | 0 | 0.0000 | 1644 |
| qtdfilvivo | 0 | 0.0000 | 22 |
| qtdfilmort | 0 | 0.0000 | 24 |
| semagestac | 0 | 0.0000 | 45 |
| gestacao | 0 | 0.0000 | 6 |
| numerolote | 0 | 0.0000 | 1168 |

```r
# Visual rápido
naniar::gg_miss_var(dados_sp_cln %>% select(any_of(present))) +
  ggtitle("% de faltantes por variável") +
  theme_minimal(base_size = 12)
```

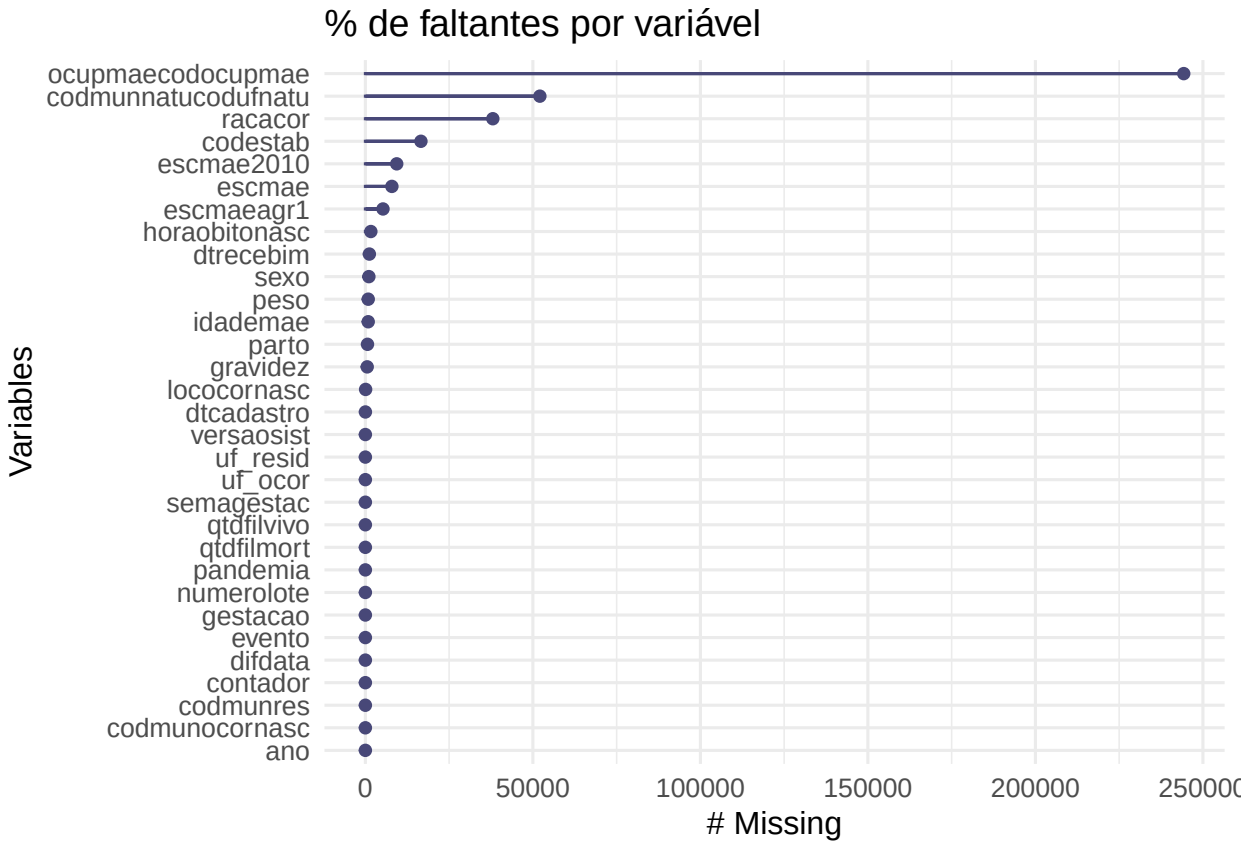


```r
# Preparação para facetas (rótulos)
dados_sp_cln_facets <- dados_sp_cln %>%
  mutate(
    evento_fac   = factor(evento, levels = c(0,1),
                          labels = c("Nascido vivo","Óbito fetal")),
    ano_fac      = factor(ano),
    pandemia_fac = factor(pandemia, levels = c(0,1),
                          labels = c("Não","Sim"))
  )

# % faltantes por variável, facetado por evento
naniar::gg_miss_var(dados_sp_cln_facets, facet = evento_fac, show_pct = TRUE) +
  labs(
    title = "% de faltantes por variável (facetas = Evento)",
    subtitle = "Comparação direta Nascido vivo vs. Óbito fetal",
    x = NULL, y = "% faltantes"
  ) +
  theme_minimal(base_size = 12)
```

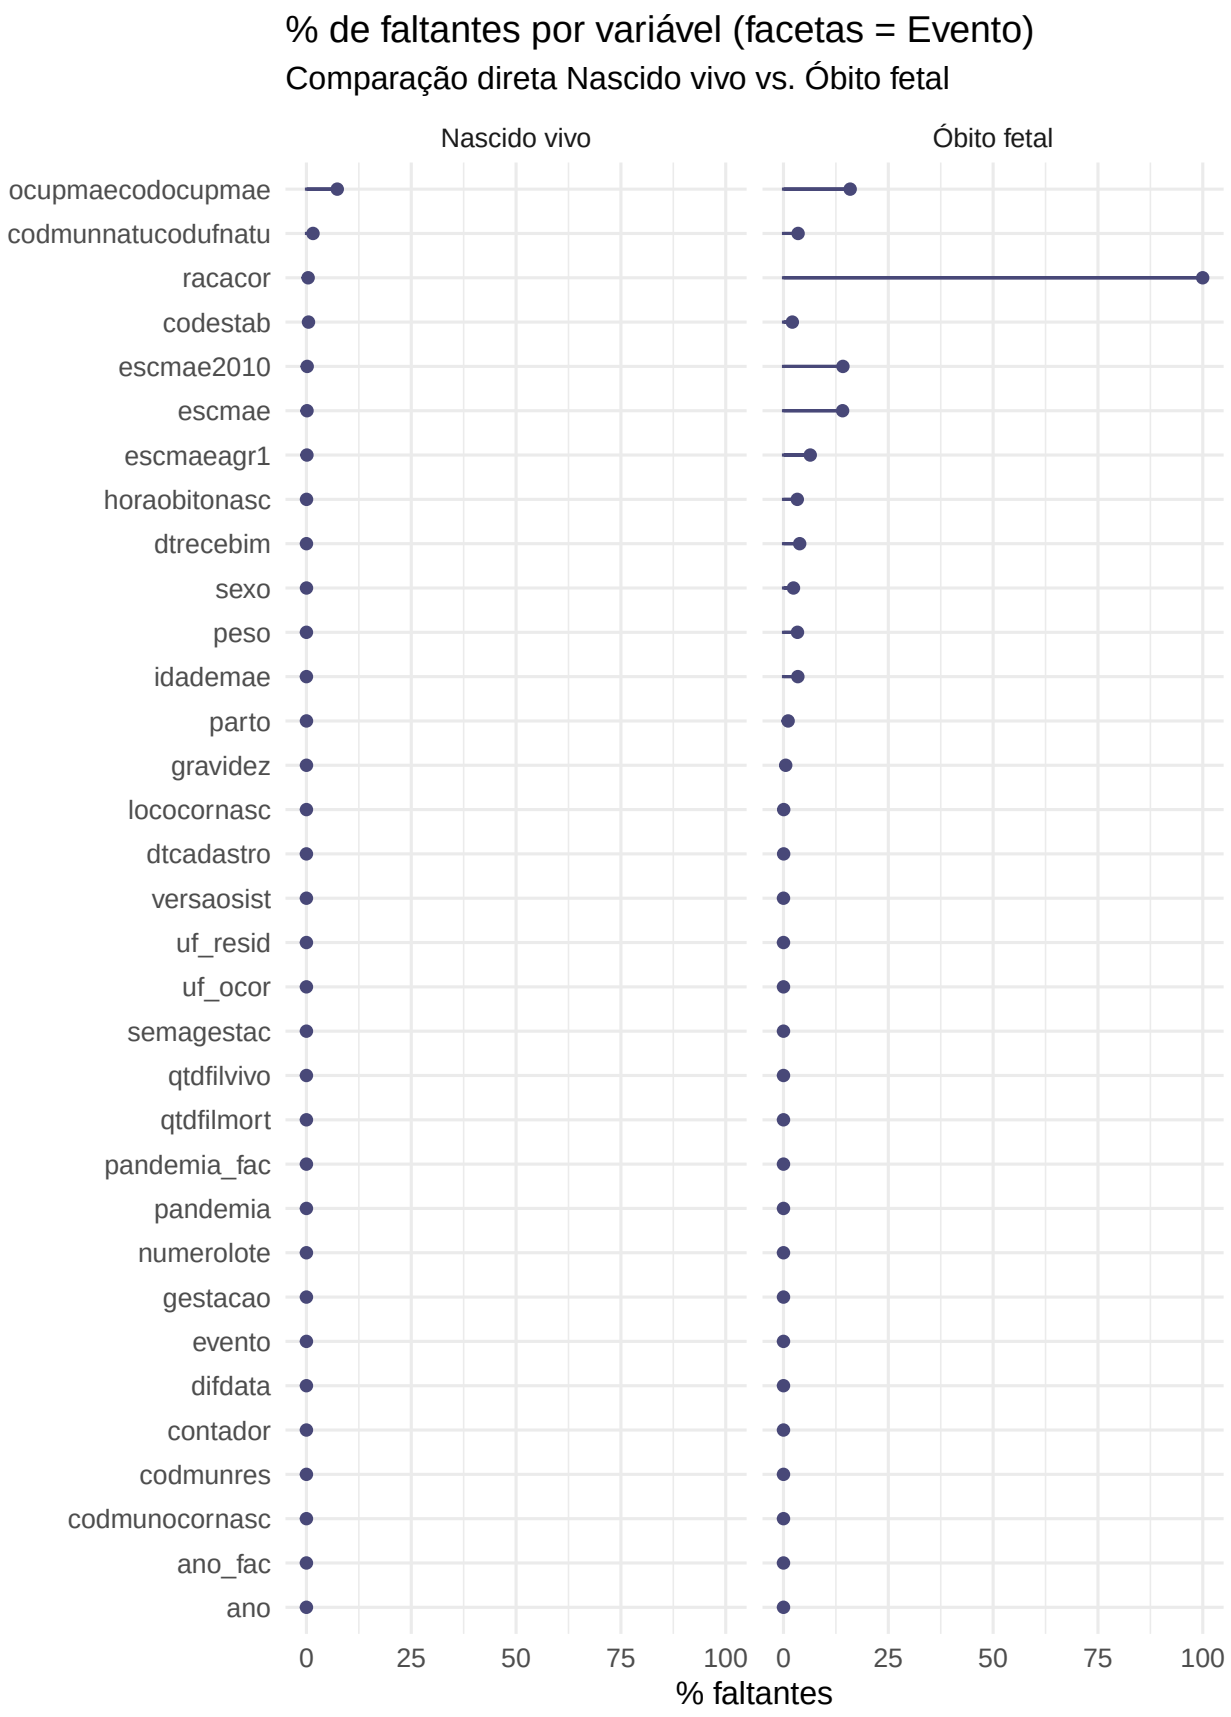
% de faltantes por variável (facetas = Evento)
Comparação direta Nascido vivo vs. Óbito fetal
Nascido vivo
Óbito fetal
ocupmaecodocupmae
codmunnatucodufnatu
racacor
codestab
escmae2010
escmae
escmaeagr1
horaobitonasc
dtrecebim
sexo
peso
idademae
parto
gravidez
lococornasc
dtcadastro
versaosist
uf_resid
uf_ocor
semagestac
qtdfilvivo
qtdfilmort
pandemia_fac
pandemia
numerolote
gestacao
evento
difdata
contador
codmunres
codmunocornasc
ano_fac
ano
0
25
50
75
100
% faltantes

```r
# % de dados faltantes por variável, facetado por ano
naniar::gg_miss_var(dados_sp_cln_facets, facet = ano_fac, show_pct = TRUE) +
  labs(
    title = "% de faltantes por variável (facetas = Ano)",
    subtitle = "Variações temporais (2018-2023)",
    x = NULL, y = "% faltantes"
  ) +
  theme_minimal(base_size = 12)
```

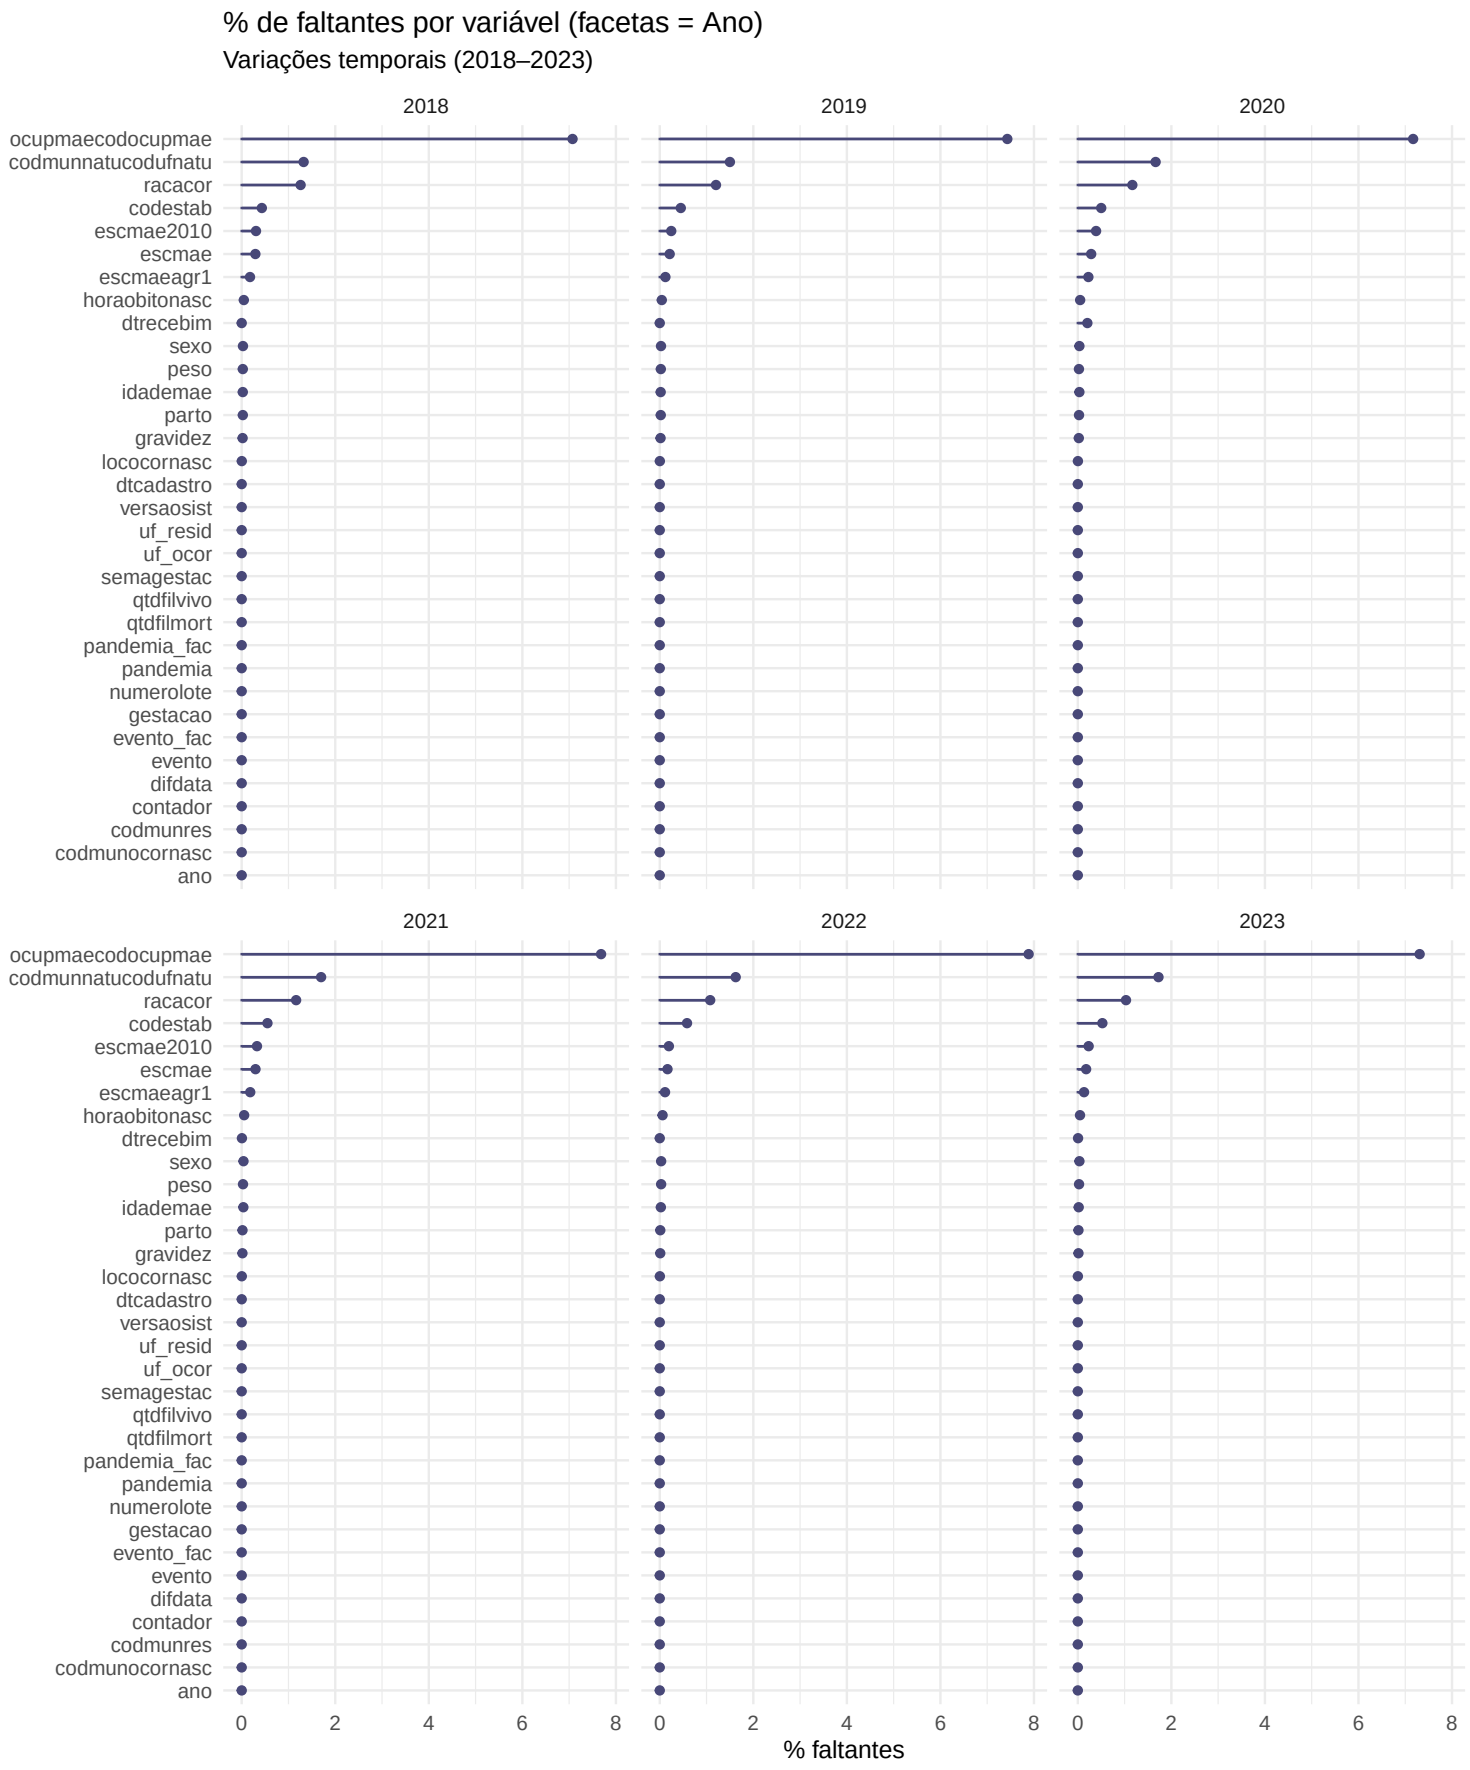
% de faltantes por variável (facetas = Ano)
Variações temporais (2018–2023)
2018
2019
2020
2021
2022
2023
ocupmaecodocupmae
codmunnatucodufnatu
racacor
codestab
escmae2010
escmae
escmaeagr1
horaobitonasc
dtrecebim
sexo
peso
idademae
parto
gravidez
lococornasc
dtcadastro
versaosist
uf_resid
uf_ocor
semagestac
qtdfilvivo
qtdfilmort
pandemia_fac
pandemia
numerolote
gestacao
evento_fac
evento
difdata
contador
codmunres
codmunocornasc
ano
0
2
4
6
8
% faltantes

```r
# Sumários de dados faltantes por variável x evento / ano
library(data.table)

DT <- as.data.table(dados_sp_cln_facets)

# Função auxiliar: proporção de NA por grupo
prop_na_by <- function(DT, by_cols){
  meltDT <- melt(DT, measure.vars = setdiff(names(DT), by_cols), variable.name = "variavel")
  meltDT[, is_na := is.na(value)]
  meltDT[, .(prop_na = mean(is_na, na.rm = TRUE)), by = c(by_cols, "variavel")]
}

# Por evento
tab_evento <- prop_na_by(DT, by_cols = "evento_fac") %>%
  tidyr::pivot_wider(names_from = evento_fac, values_from = prop_na) %>%
  mutate(diff_abs = abs(`Óbito fetal` - `Nascido vivo`)) %>%
  arrange(desc(diff_abs))

knitr::kable(head(tab_evento, 30), digits = 3,
             caption = "Top 30 variáveis com maior diferença de % faltantes entre eventos")
```

Table 2: Top 30 variáveis com maior diferença de % faltantes entre eventos

| variavel | Óbito fetal | Nascido vivo | diff_abs |
|---|---|---|---|
| racacor | 1.000 | 0.004 | 0.996 |
| escmae2010 | 0.142 | 0.002 | 0.140 |
| escmae | 0.141 | 0.001 | 0.140 |
| ocupmaecodocupmae | 0.159 | 0.073 | 0.086 |
| escmaeagr1 | 0.064 | 0.001 | 0.063 |
| dtrecebim | 0.039 | 0.000 | 0.039 |
| idademae | 0.034 | 0.000 | 0.034 |
| peso | 0.033 | 0.000 | 0.033 |
| horaobitonasc | 0.033 | 0.000 | 0.033 |
| sexo | 0.024 | 0.000 | 0.024 |
| codmunnatucodufnatu | 0.035 | 0.016 | 0.019 |
| codestab | 0.021 | 0.005 | 0.016 |
| parto | 0.011 | 0.000 | 0.011 |
| gravidez | 0.005 | 0.000 | 0.005 |
| lococornasc | 0.001 | 0.000 | 0.001 |
| dtcadastro | 0.000 | 0.000 | 0.000 |
| codmunres | 0.000 | 0.000 | 0.000 |
| qtdfilvivo | 0.000 | 0.000 | 0.000 |
| qtdfilmort | 0.000 | 0.000 | 0.000 |
| semagestac | 0.000 | 0.000 | 0.000 |
| gestacao | 0.000 | 0.000 | 0.000 |
| numerolote | 0.000 | 0.000 | 0.000 |
| versaosist | 0.000 | 0.000 | 0.000 |
| difdata | 0.000 | 0.000 | 0.000 |
| contador | 0.000 | 0.000 | 0.000 |
| codmunocornasc | 0.000 | 0.000 | 0.000 |
| uf_ocor | 0.000 | 0.000 | 0.000 |
| uf_resid | 0.000 | 0.000 | 0.000 |
| ano | 0.000 | 0.000 | 0.000 |
| evento | 0.000 | 0.000 | 0.000 |

```r
# Por ano
tab_ano <- prop_na_by(DT, by_cols = "ano_fac") %>%
  tidyr::pivot_longer(-c(variavel, ano_fac), names_to = "metric", values_to = "prop_na")

knitr::kable(tab_ano %>% group_by(variavel) %>% summarise(prop_na_média = mean(prop_na, na.rm=TRUE)) %>%
               arrange(desc(prop_na_média)) %>% head(30),
             digits = 3,
             caption = "Top 30 variáveis com maior % médio de faltantes ao longo dos anos")
```

Table 3: Top 30 variáveis com maior % médio de faltantes ao longo dos anos

| variavel | prop_na_média |
|---|---|
| ocupmaecodocupmae | 0.074 |
| codmunnatucodufnatu | 0.016 |
| racacor | 0.011 |
| codestab | 0.005 |
| escmae2010 | 0.003 |
| escmae | 0.002 |
| escmaeagr1 | 0.002 |
| horaobitonasc | 0.000 |
| dtrecebim | 0.000 |
| sexo | 0.000 |
| peso | 0.000 |
| idademae | 0.000 |
| parto | 0.000 |
| gravidez | 0.000 |
| lococornasc | 0.000 |
| dtcadastro | 0.000 |
| codmunres | 0.000 |
| qtdfilvivo | 0.000 |
| qtdfilmort | 0.000 |
| semagestac | 0.000 |
| gestacao | 0.000 |
| numerolote | 0.000 |
| versaosist | 0.000 |
| difdata | 0.000 |
| contador | 0.000 |
| codmunocornasc | 0.000 |
| uf_ocor | 0.000 |
| uf_resid | 0.000 |
| ano | 0.000 |
| evento | 0.000 |

# 5. Recodificações principais e criação de objetos de tempo/evento

```r
# Recodificação essencial para análises seguintes
dados_eda <- dados_sp_cln %>%
  mutate(
    sexo = case_when(sexo %in% c("1","2") ~ sexo, TRUE ~ NA_character_) %>%
        factor(levels = c("1","2"), labels = c("Masculino","Feminino")),
    gravidez = case_when(
      gravidez == "1" ~ "Única",
      gravidez == "2" ~ "Dupla",
```

```r
      gravidez == "3" ~ "Tripla ou mais",
      TRUE ~ NA_character_) %>%
      factor(levels = c("Única","Dupla","Tripla ou mais")),
    parto = factor(parto, levels = c("1","2"), labels = c("Vaginal","Cesáreo")),
    lococornasc = case_when(
      lococornasc == "1" ~ "Hospital",
      lococornasc == "2" ~ "Outros est. saúde",
      lococornasc == "3" ~ "Domicílio",
      lococornasc == "4" ~ "Via pública",
      lococornasc == "5" ~ "Outros",
      TRUE ~ NA_character_) %>%
      factor(levels = c("Hospital","Outros est. saúde","Domicílio",
                        "Via pública","Outros")),
    pandemia = factor(pandemia, levels = c(0,1), labels = c("Não","Sim")),
    # Objetos de tempo e eventos para as duas perspectivas
    tempo = semagestac,
    status_fd = ifelse(evento == 1L, 1L, 0L),   # 1 = óbito fetal
    status_lv = ifelse(evento == 0L, 1L, 0L),   # 1 = nascimento vivo
    fstatus   = case_when(evento == 1L ~ 1L,    # 1 = óbito fetal
                          evento == 0L ~ 2L,    # 2 = nascido vivo (competidor)
                          TRUE ~ 0L)            # 0 = censura
  ) %>%
  # remove linhas sem tempo ou evento definido
  filter(!is.na(tempo), !is.na(fstatus))
```

## 6. Descrição básica

```r
# Tamanho e taxa bruta de eventos
n <- nrow(dados_eda)
taxa_obito <- mean(dados_eda$status_fd)
tab_evento <- table(Evento = ifelse(dados_eda$status_fd==1,"Óbito fetal","Nascido vivo"))

list(n_registros = n, taxa_óbito_fetal = round(taxa_obito, 4))
```

```
## $n_registros
## [1] 3294871
##
## $taxa_óbito_fetal
## [1] 0.0075
```

```r
tab_evento
```

```
## Evento
## Nascido vivo  Óbito fetal
##      3270086        24785
```

```r
# Distribuições de idade gestacional, idade materna e peso
p1 <- ggplot(dados_eda, aes(x = tempo)) +
  geom_histogram(bins = 60) + labs(x="Semanas de gestação", y="Frequência",
                                   title="Distribuição de idade gestacional (tempo)") +
  theme_minimal(base_size = 12)
p1
```

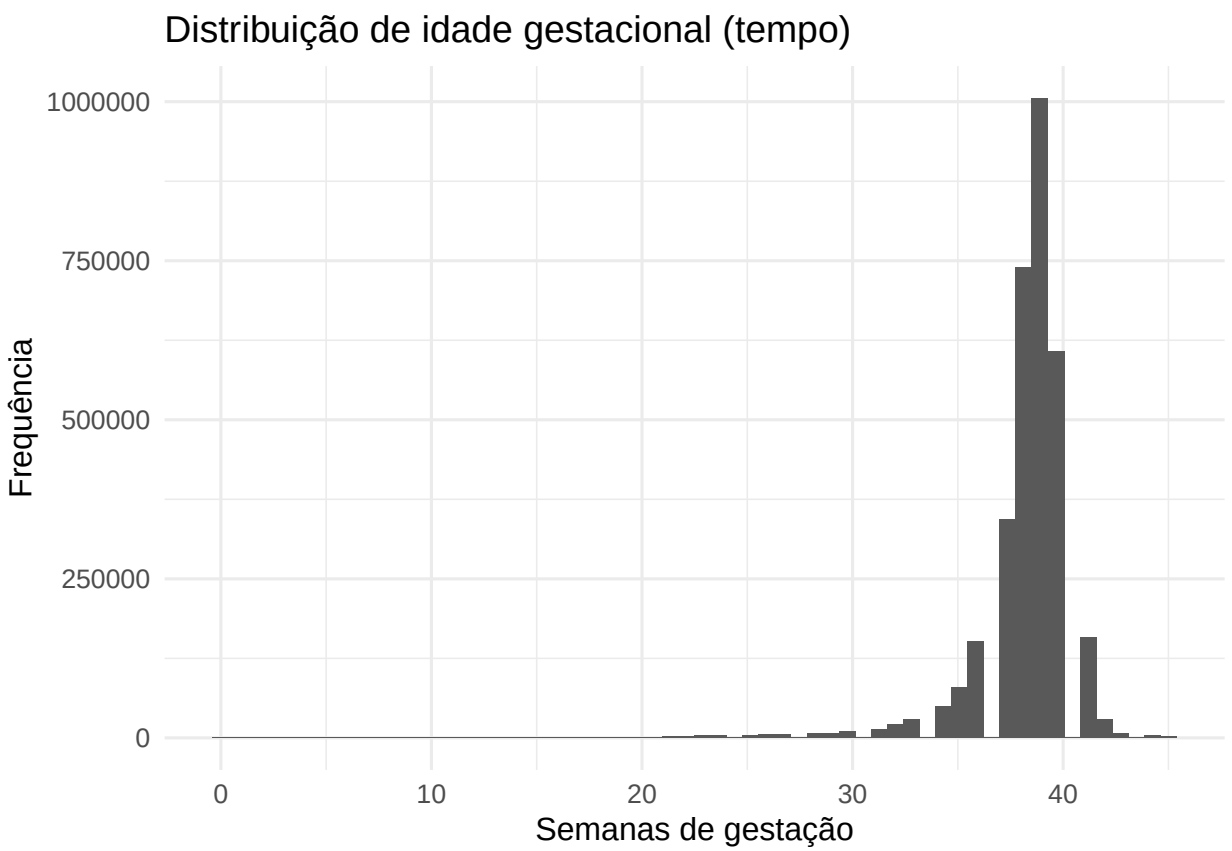


```
p2 <- ggplot(dados_eda, aes(x = idademae)) +
  geom_histogram(bins = 60) + labs(x="Idade materna (anos)", y="Frequência") +
  theme_minimal(base_size = 12)
p2
```

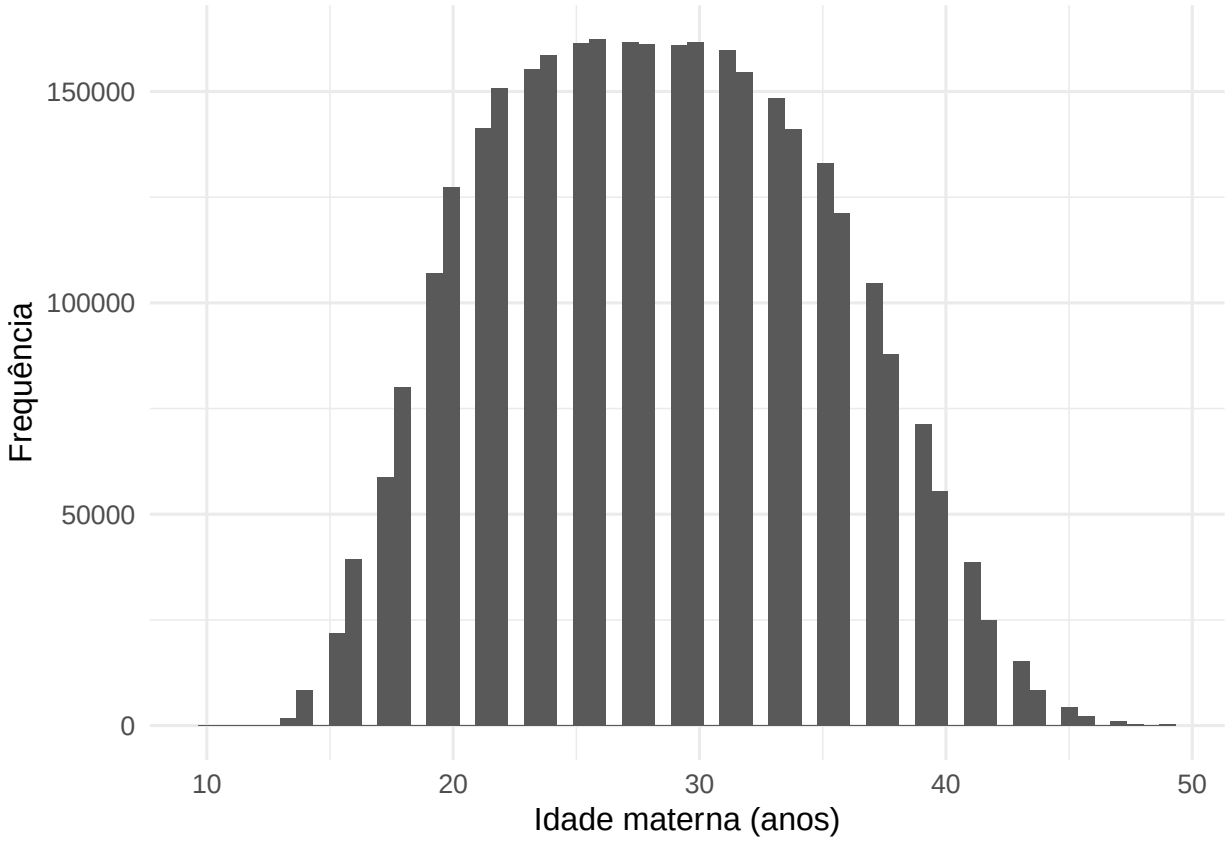


```
p3 <- ggplot(dados_eda, aes(x = peso)) +
  geom_histogram(bins = 60) + labs(x="Peso ao nascer (g)", y="Frequência") +
  theme_minimal(base_size = 12)
p3
```

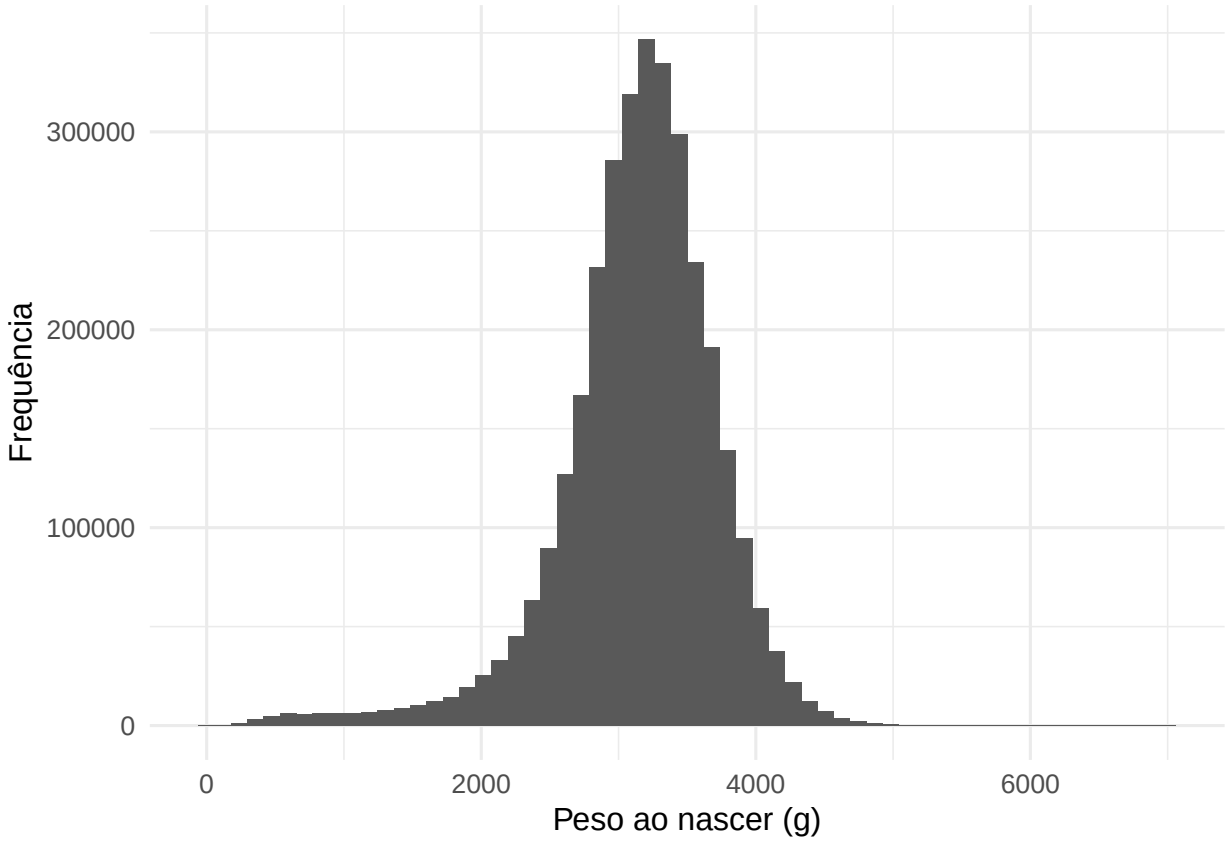


## 6.1 Kaplan–Meier (KM) sob as duas perspectivas

```
# Óbito fetal como evento (censura = nascido vivo)
km_fd <- survfit(Surv(tempo, status_fd) ~ 1, data = dados_eda)
survminer::ggsurvplot(
  km_fd, data = dados_eda, conf.int = TRUE,
  xlab = "Semanas", ylab = "S(t) (óbito fetal como evento)",
  title = "KM - Óbito fetal (nascido vivo censurado)",
  ggtheme = theme_minimal(base_size = 12),
  ylim = c(0.985, 1.00)   # Zoom
)
```

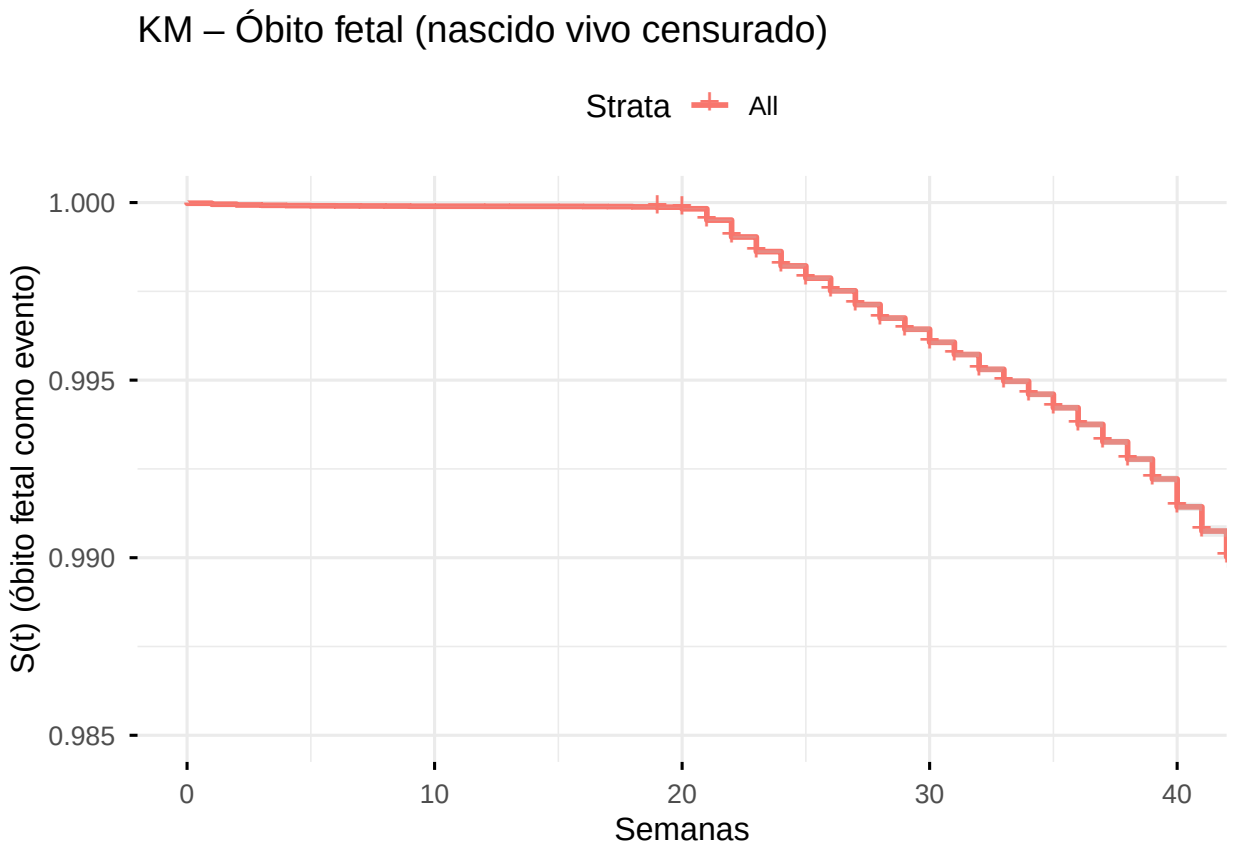


```r
# Nascido vivo como evento (óbito fetal censurado)
km_lv <- survfit(Surv(tempo, status_lv) ~ 1, data = dados_eda)
survminer::ggsurvplot(km_lv, data = dados_eda, conf.int = TRUE,
                      xlab = "Semanas", ylab = "S(t) (nascido vivo como evento)",
                      title = "KM - Nascido vivo (óbito fetal censurado)",
                      ggtheme = theme_minimal(base_size = 12))
```

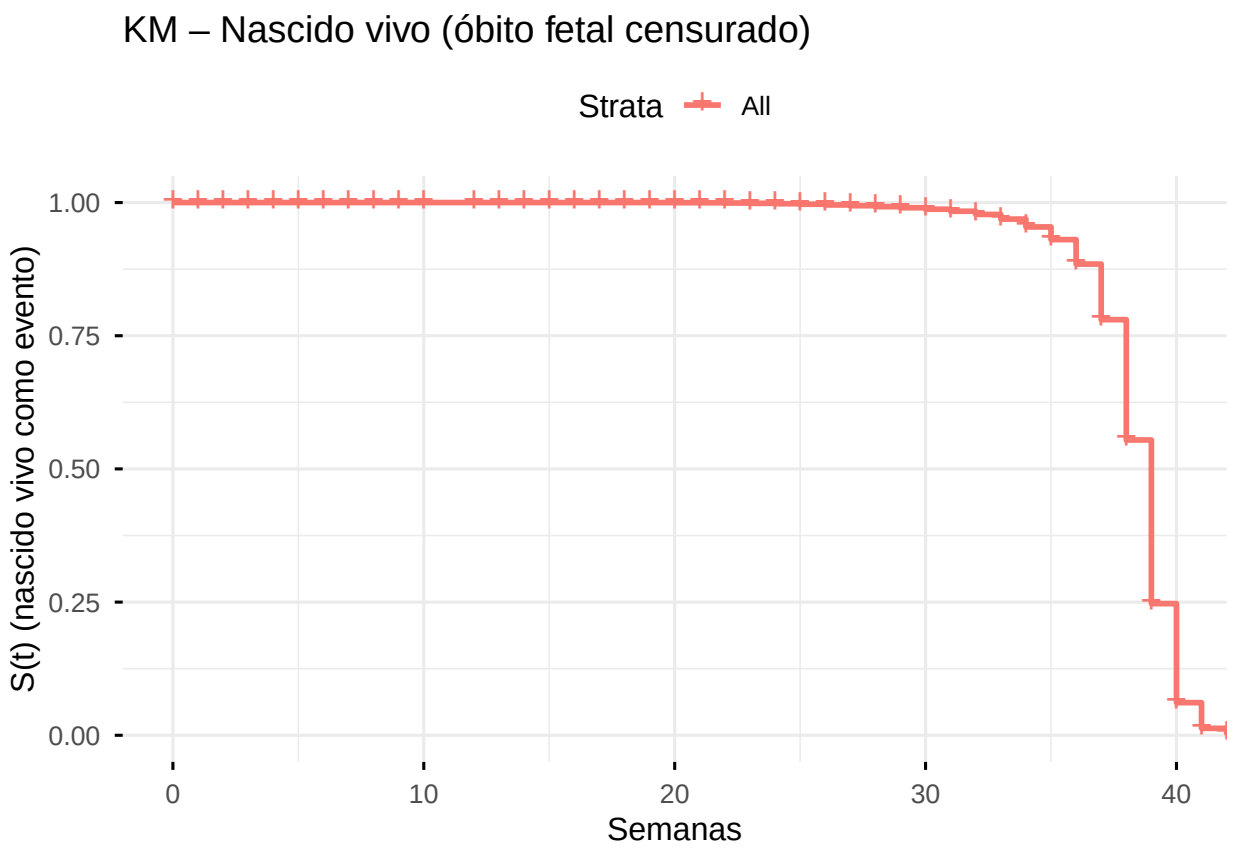


## 7. KM de cada caso

### Sexo

```r
# Óbito fetal como evento (censura = nascido vivo)
km_fd_sexo <- survfit(Surv(tempo, status_fd) ~ sexo, data = dados_eda)
survminer::ggsurvplot(
  km_fd_sexo, data = dados_eda, conf.int = TRUE,
  xlab = "Semanas", ylab = "S(t) - óbito fetal",
  title = "KM - Óbito fetal (censura: nascido vivo) por sexo",
  ggtheme = theme_minimal(base_size = 12),
  ylim = c(0.987, 1.00)
)
```

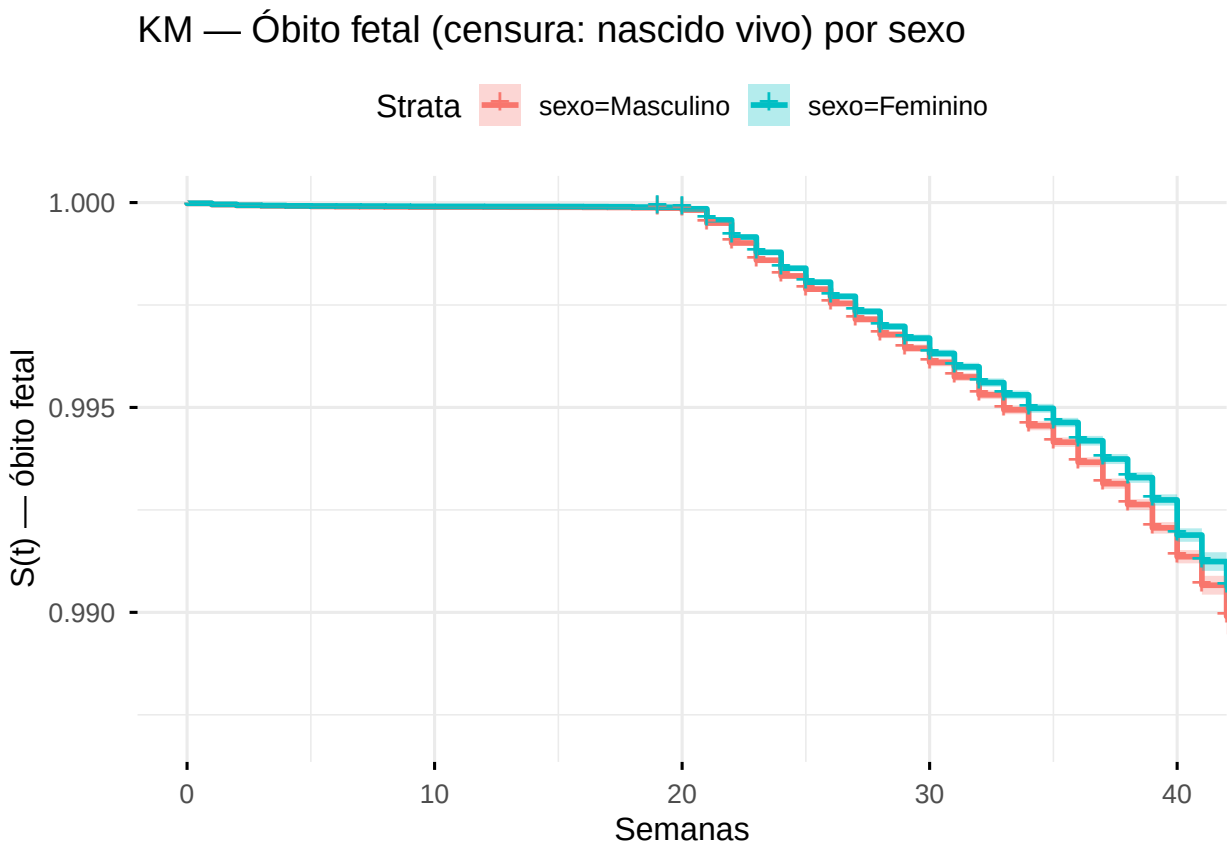


```r
# Nascido vivo como evento (óbito fetal censurado)
km_lv_sexo <- survfit(Surv(tempo, status_lv) ~ sexo, data = dados_eda)
survminer::ggsurvplot(
  km_lv_sexo, data = dados_eda, conf.int = TRUE,
  xlab = "Semanas", ylab = "S(t) - nascido vivo",
  title = "KM - Nascido vivo (censura: óbito fetal) por sexo",
  ggtheme = theme_minimal(base_size = 12)
)
```

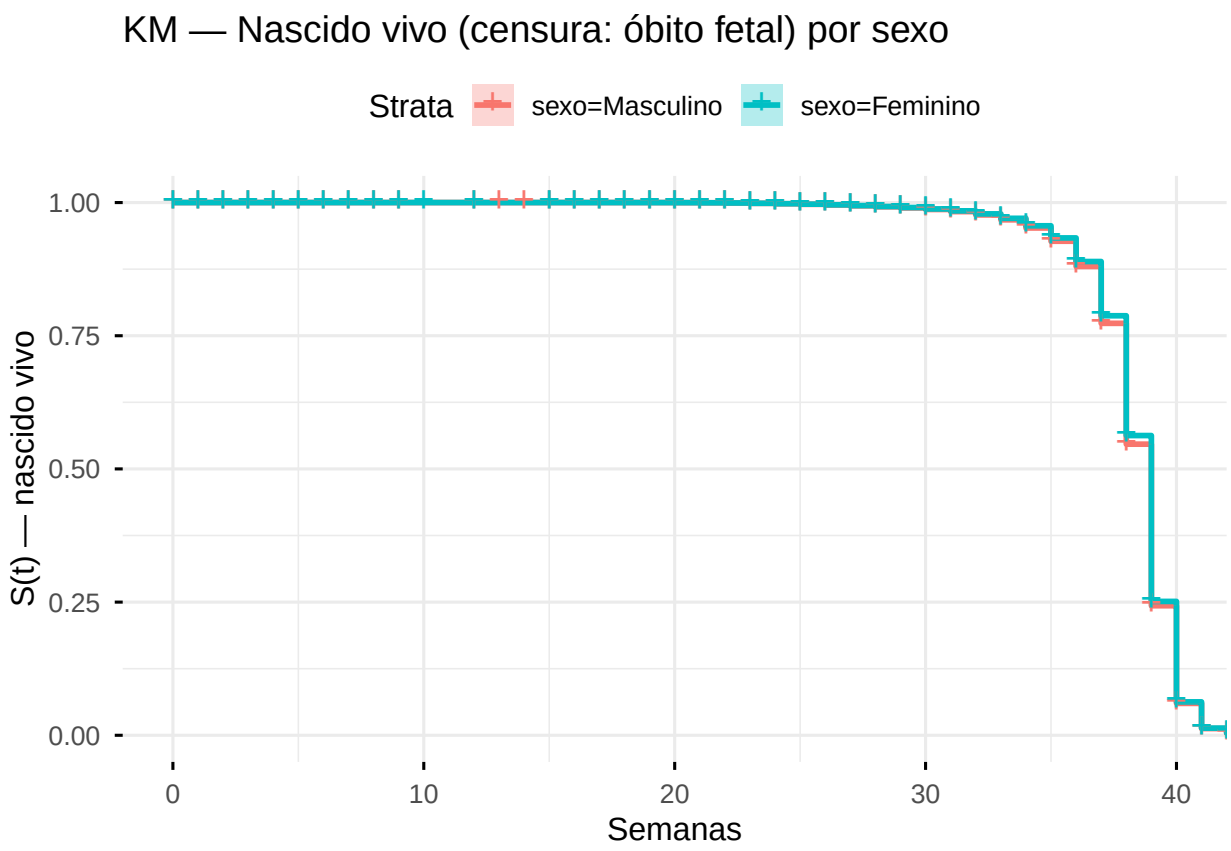


**Ano**

```
dados_eda <- dados_eda %>%
  dplyr::mutate(ano = factor(ano, levels = sort(unique(ano)), ordered = TRUE))

# Óbito fetal como evento (censura = nascido vivo)
km_fd_ano <- survfit(Surv(tempo, status_fd) ~ ano, data = dados_eda)
survminer::ggsurvplot(
  km_fd_ano, data = dados_eda, conf.int = TRUE,
  xlab = "Semanas", ylab = "S(t) - óbito fetal",
  title = "KM - Óbito fetal (censura: nascido vivo) por ano",
  ggtheme = theme_minimal(base_size = 12),
  ylim = c(0.987, 1.00)
)
```

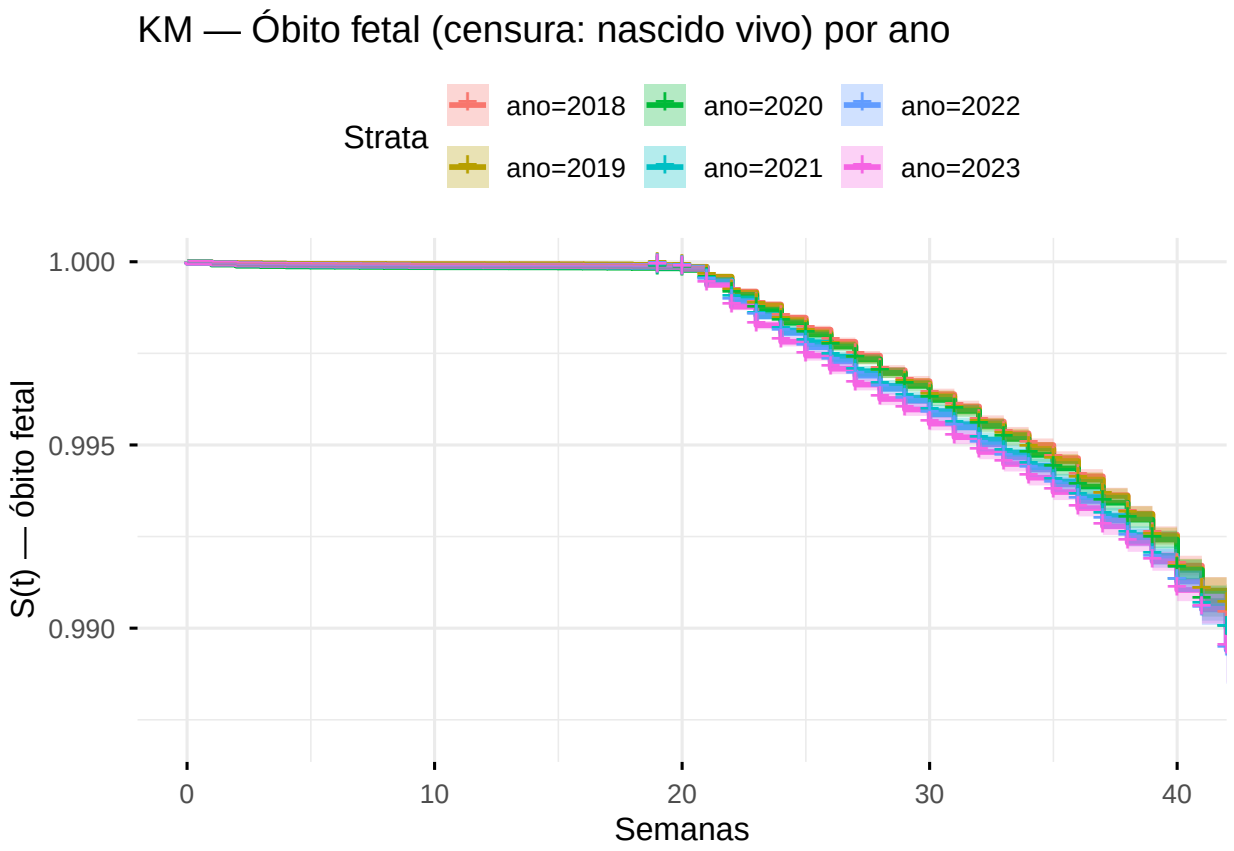


```r
# Nascido vivo como evento (óbito fetal censurado)
km_lv_ano <- survfit(Surv(tempo, status_lv) ~ ano, data = dados_eda)
survminer::ggsurvplot(
  km_lv_ano, data = dados_eda, conf.int = TRUE,
  xlab = "Semanas", ylab = "S(t) - nascido vivo",
  title = "KM - Nascido vivo (censura: óbito fetal) por ano",
  ggtheme = theme_minimal(base_size = 12)
)
```

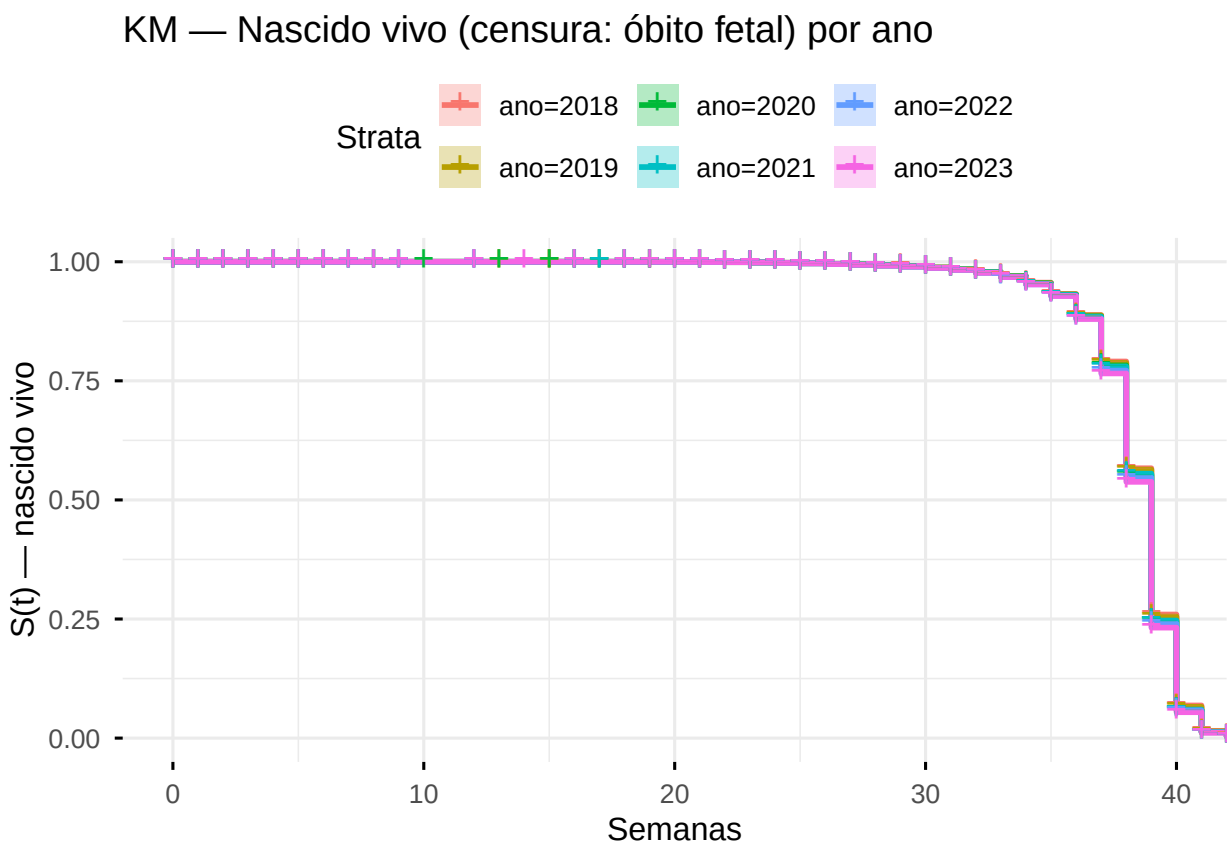


### Pandemia

```
dados_eda <- dados_eda %>%
  dplyr::mutate(ano = factor(ano, levels = sort(unique(ano)), ordered = TRUE))

# Óbito fetal como evento (censura = nascido vivo)
km_fd_pandemia <- survfit(Surv(tempo, status_fd) ~ pandemia, data = dados_eda)
survminer::ggsurvplot(
  km_fd_pandemia, data = dados_eda, conf.int = TRUE,
  xlab = "Semanas", ylab = "S(t) - óbito fetal",
  title = "KM - Óbito fetal (censura: nascido vivo) por pandemia",
  ggtheme = theme_minimal(base_size = 12),
  ylim = c(0.987, 1.00)
)
```

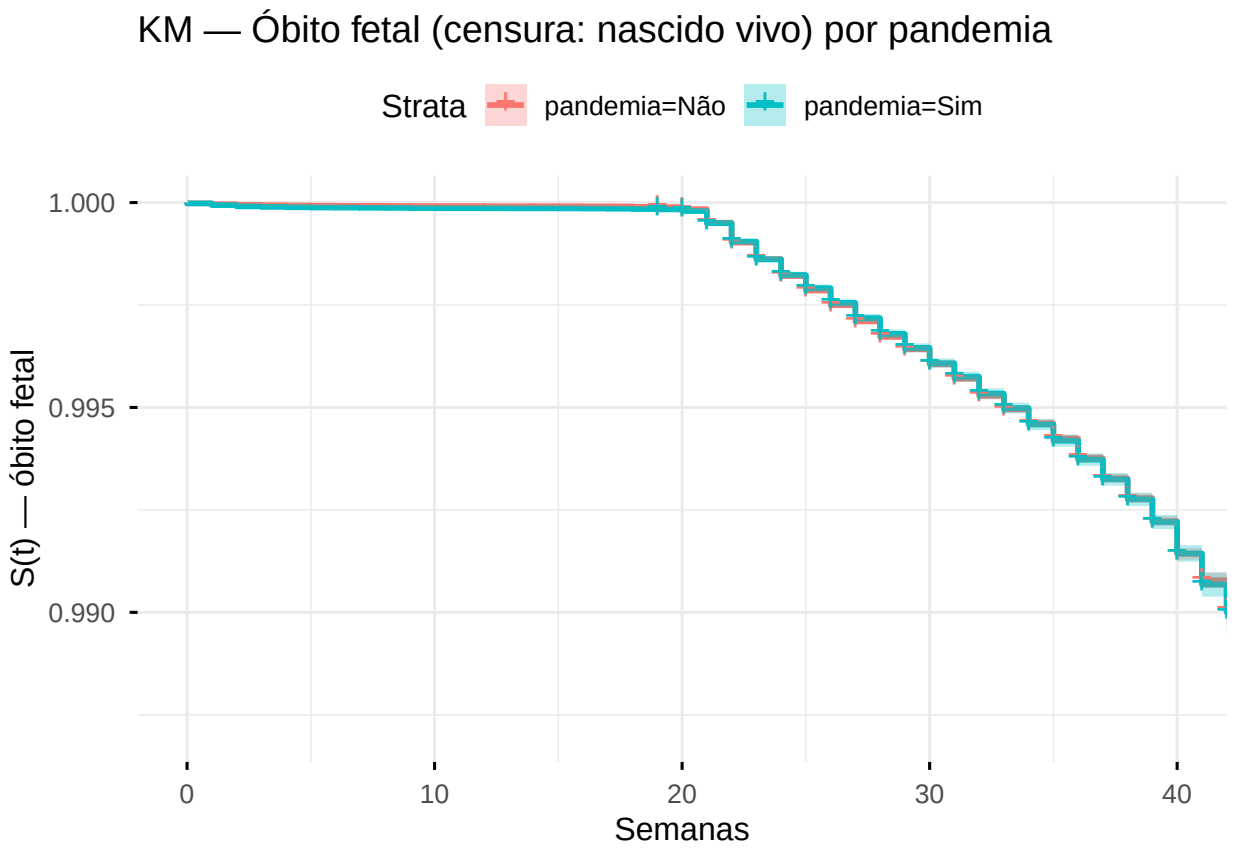


```r
# Nascido vivo como evento (óbito fetal censurado)
km_lv_pandemia <- survfit(Surv(tempo, status_lv) ~ pandemia, data = dados_eda)
survminer::ggsurvplot(
  km_lv_pandemia, data = dados_eda, conf.int = TRUE,
  xlab = "Semanas", ylab = "S(t) - nascido vivo",
  title = "KM - Nascido vivo (censura: óbito fetal) por pandemia",
  ggtheme = theme_minimal(base_size = 12)
)
```

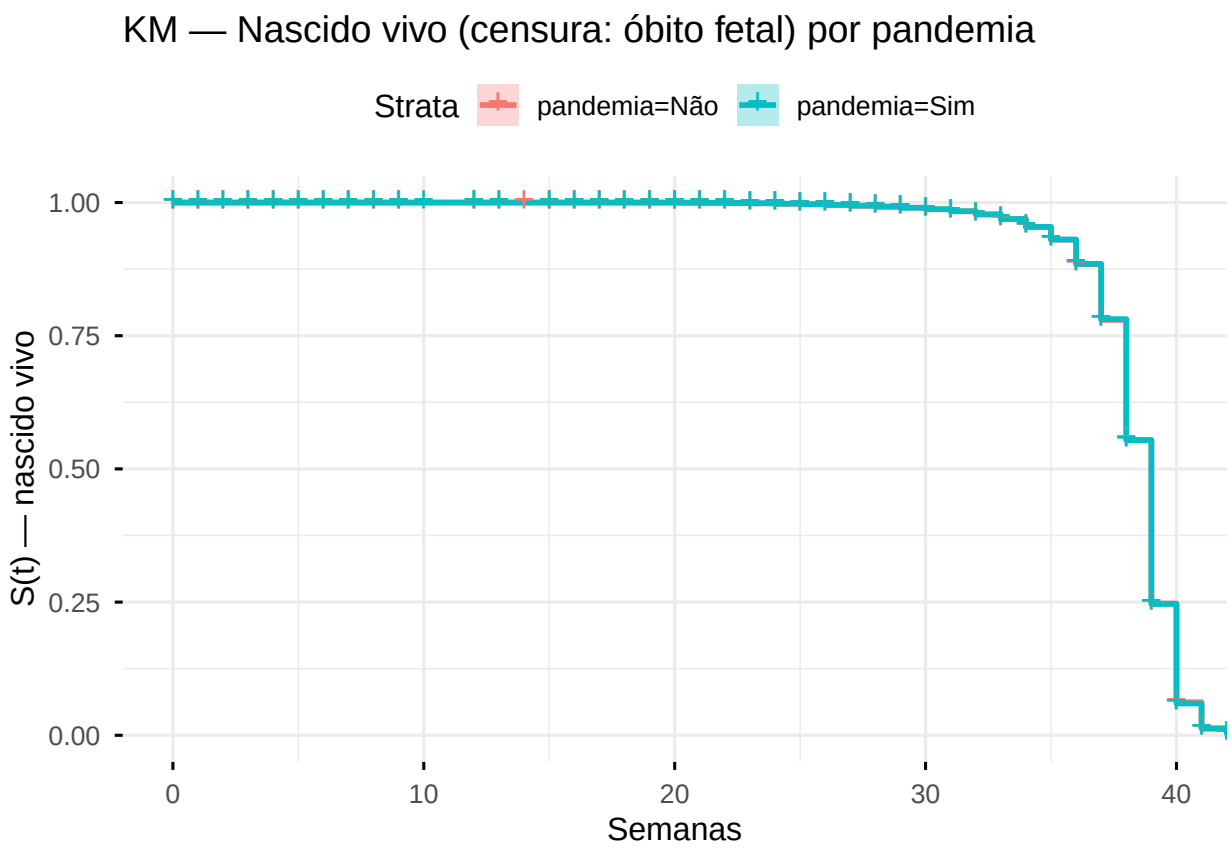


### Idade da mãe

```
# Cria faixas etárias usuais (OMS)
dados_eda <- dados_eda %>%
  dplyr::mutate(
    idade_cat = dplyr::case_when(
      is.na(idademae)                ~ NA_character_,
      idademae < 20                  ~ "<20",
      idademae >= 20 & idademae <= 34 ~ "20-34",
      idademae >= 35 & idademae <= 39 ~ "35-39",
      idademae >= 40                 ~ " 40"
    ) %>% factor(levels = c("<20","20-34","35-39"," 40"))
  )

# Óbito fetal como evento (censura = nascido vivo)
km_fd_idade <- survfit(Surv(tempo, status_fd) ~ idade_cat, data = dados_eda)
survminer::ggsurvplot(
  km_fd_idade, data = dados_eda, conf.int = TRUE,
  xlab = "Semanas", ylab = "S(t) - óbito fetal",
  title = "KM - Óbito fetal (censura: nascido vivo) por idade materna",
  ggtheme = theme_minimal(base_size = 12),
  ylim = c(0.987, 1.00)
)
```

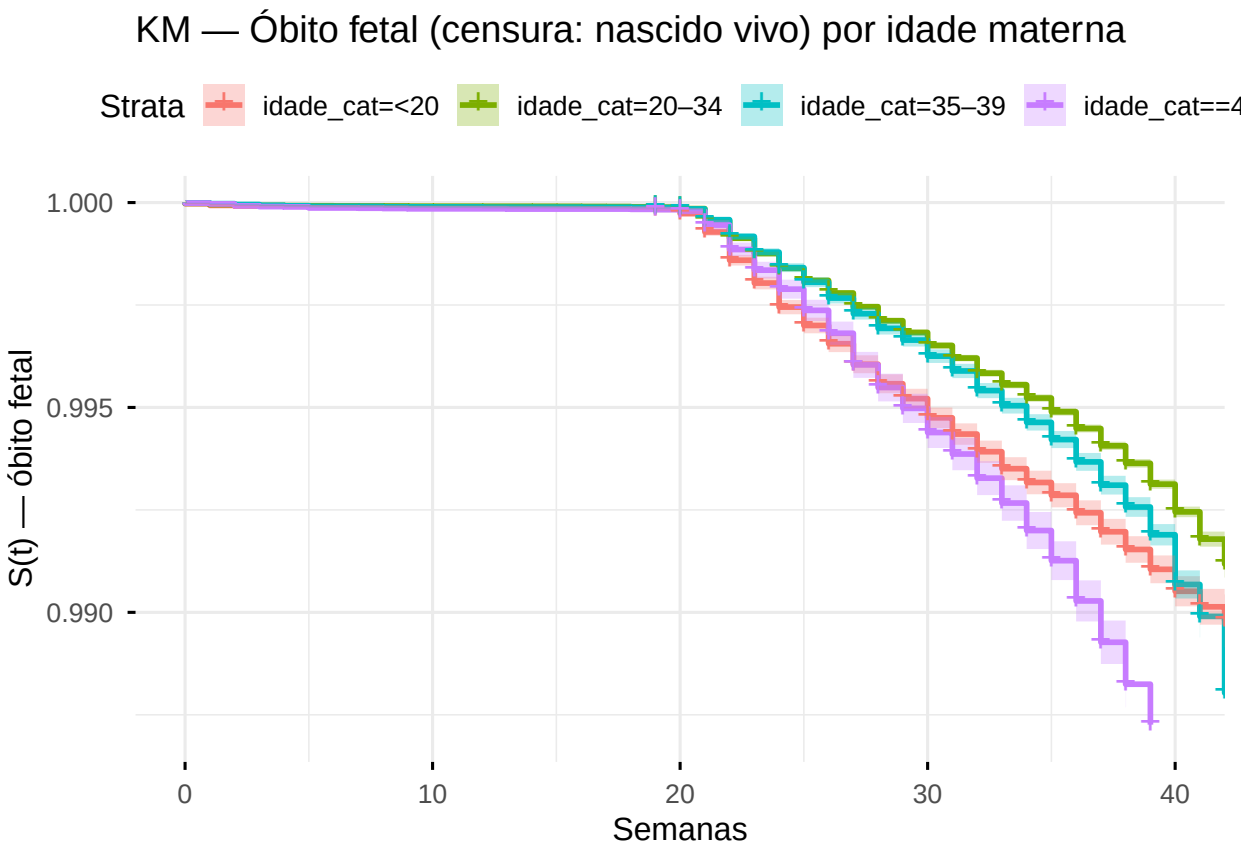


```r
# Nascido vivo como evento (óbito fetal censurado)
km_lv_idade <- survfit(Surv(tempo, status_lv) ~ idade_cat, data = dados_eda)
survminer::ggsurvplot(
  km_lv_idade, data = dados_eda, conf.int = TRUE,
  xlab = "Semanas", ylab = "S(t) - nascido vivo",
  title = "KM - Nascido vivo (censura: óbito fetal) por idade materna",
  ggtheme = theme_minimal(base_size = 12)
)
```

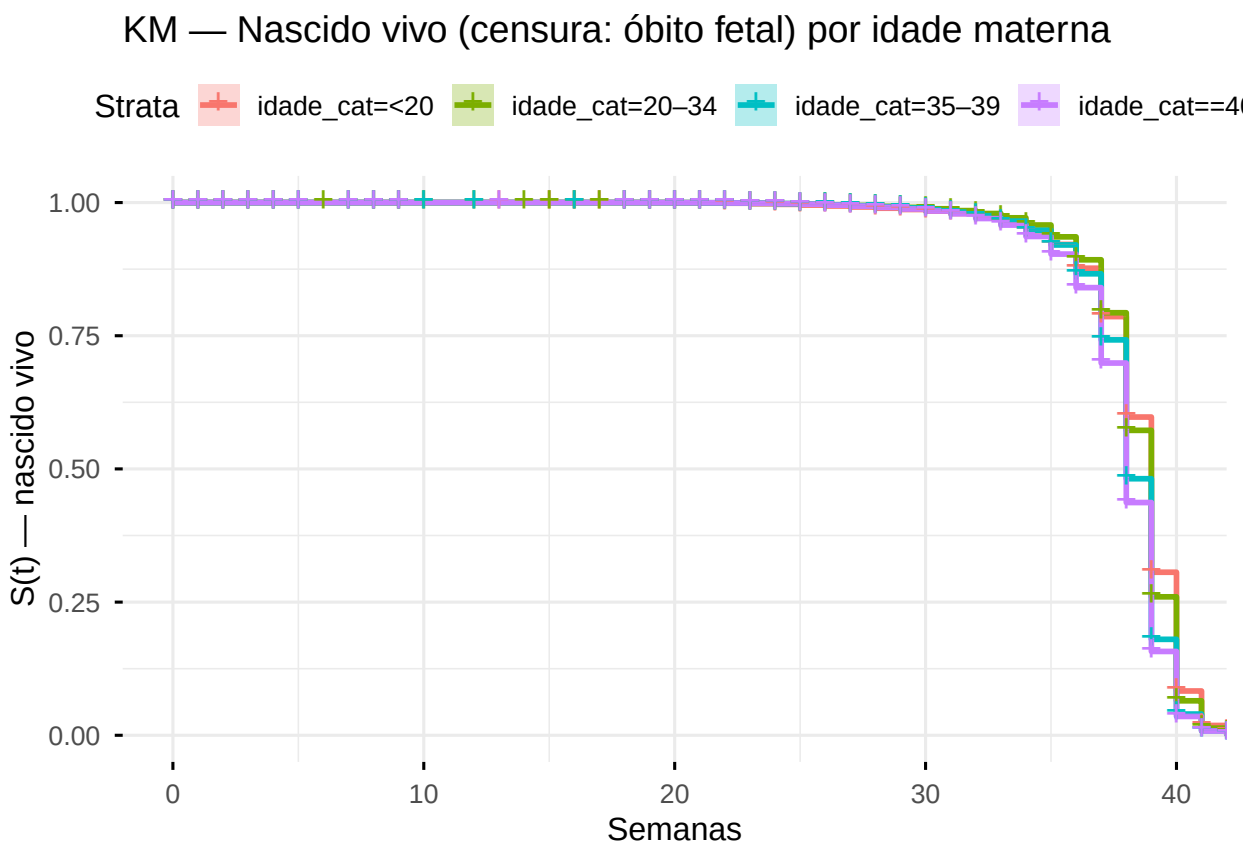


**Peso**

```
# Cria faixas de peso
dados_eda <- dados_eda %>%
  dplyr::mutate(
    peso_cat = dplyr::case_when(
      is.na(peso)               ~ NA_character_,
      peso < 2500               ~ "<2500g",
      peso >= 2500 & peso < 4000 ~ "2500-3999g",
      peso >= 4000              ~ " 4000g"
    ) %>% factor(levels = c("<2500g","2500-3999g"," 4000g"))
  )

# Óbito fetal como evento (censura = nascido vivo)
km_fd_peso <- survfit(Surv(tempo, status_fd) ~ peso_cat, data = dados_eda)
survminer::ggsurvplot(
  km_fd_peso, data = dados_eda, conf.int = TRUE,
  xlab = "Semanas", ylab = "S(t) - óbito fetal",
  title = "KM - Óbito fetal (censura: nascido vivo) por peso ao nascer",
  ggtheme = theme_minimal(base_size = 12),
  ylim = c(0.987, 1.00)
)
```

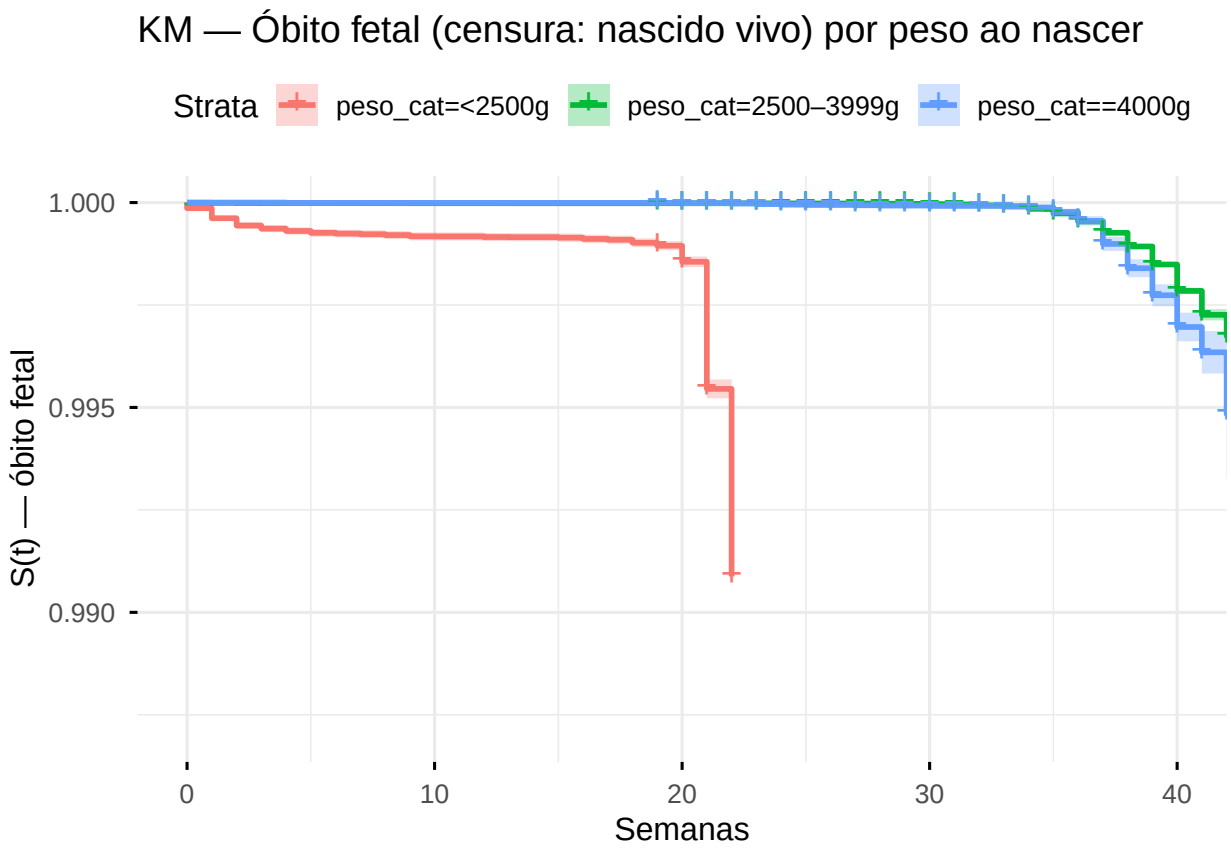


```r
# Nascido vivo como evento (óbito fetal censurado)
km_lv_peso <- survfit(Surv(tempo, status_lv) ~ peso_cat, data = dados_eda)
survminer::ggsurvplot(
  km_lv_peso, data = dados_eda, conf.int = TRUE,
  xlab = "Semanas", ylab = "S(t) - nascido vivo",
  title = "KM - Nascido vivo (censura: óbito fetal) por peso ao nascer",
  ggtheme = theme_minimal(base_size = 12)
)
```

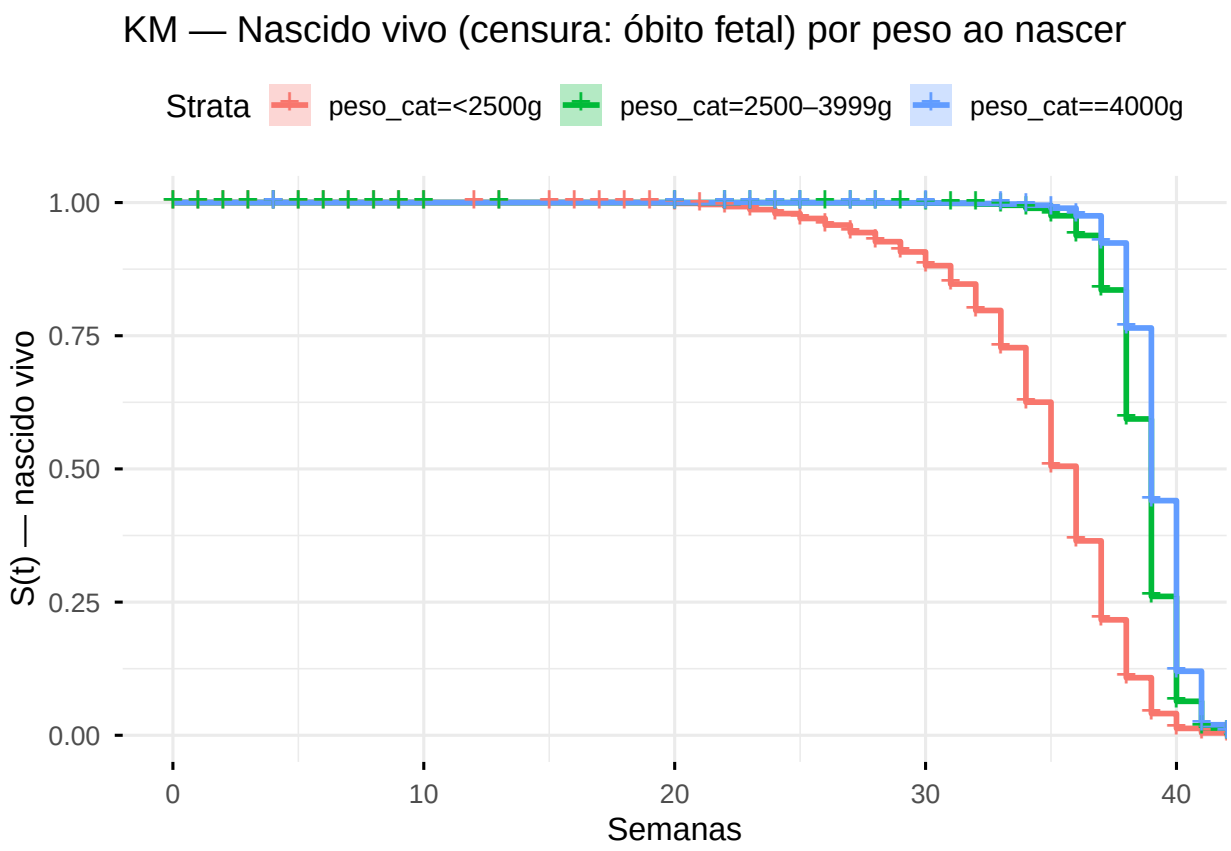


### Parto

```r
dados_parto <- subset(dados_eda, !is.na(tempo) & !is.na(status_fd) & !is.na(parto))
table(dados_eda$parto, useNA = "ifany")
```

```
##
## Vaginal Cesáreo    <NA>
## 1345422 1948818     631
```

```r
with(dados_eda, table(is.na(tempo) | is.na(status_fd), useNA = "ifany"))
```

```
##
##   FALSE
## 3294871
```

```r
# Óbito fetal como evento (censura = nascido vivo)
km_fd_parto <- survfit(Surv(tempo, status_fd) ~ parto, data = dados_parto)
survminer::ggsurvplot(
  km_fd_parto, data = dados_parto, conf.int = TRUE,
  conf.int.style = "step", linetype = 1, size = 0.7,
  xlab = "Semanas", ylab = "S(t) - óbito fetal",
  title = "KM - Óbito fetal (censura: nascido vivo) por tipo de parto",
  ggtheme = theme_minimal(base_size = 12),
  ylim = c(0.987, 1.00)
)
```

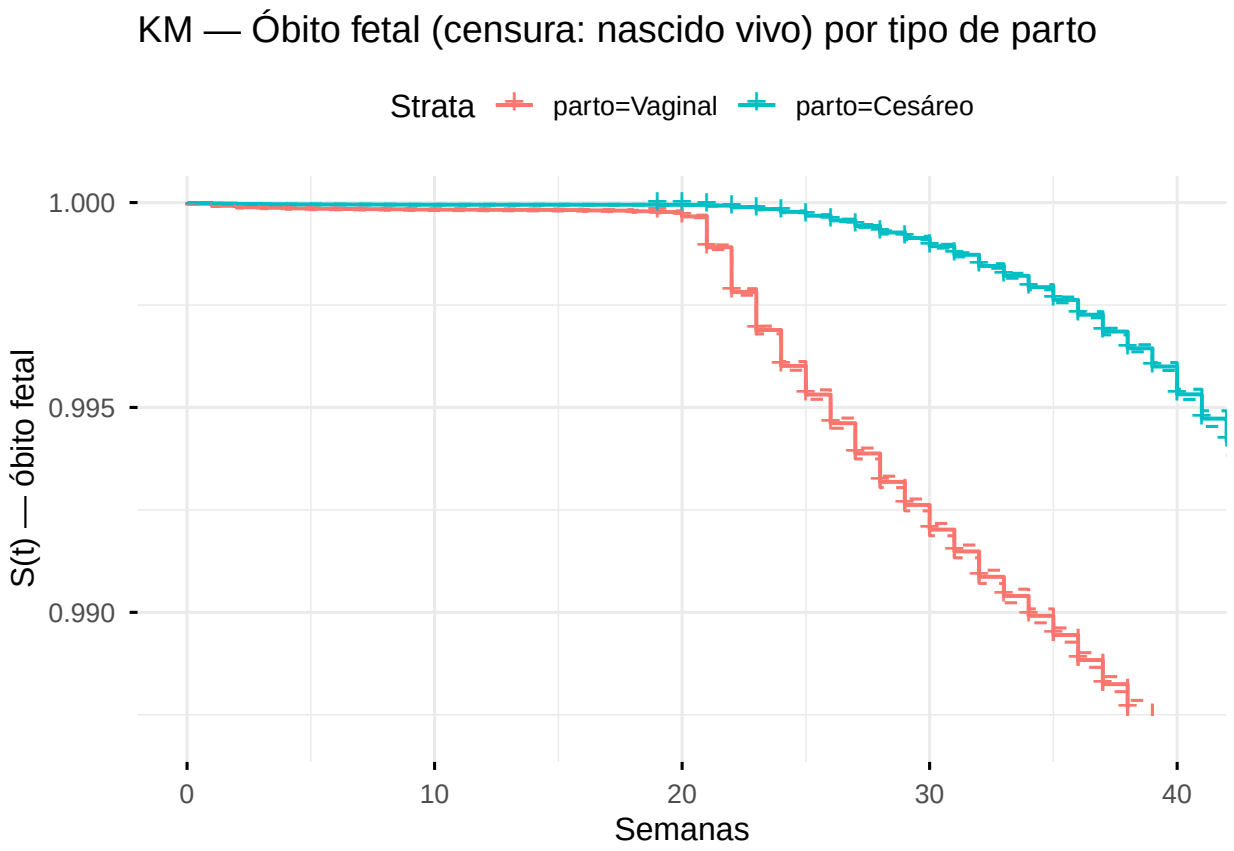


```r
# Nascido vivo como evento (óbito fetal censurado)
km_lv_parto <- survfit(Surv(tempo, status_lv) ~ parto, data = dados_parto)
survminer::ggsurvplot(
  km_lv_parto, data = dados_parto, conf.int = TRUE,
  conf.int.style = "step", linetype = 1, size = 0.7,
  xlab = "Semanas", ylab = "S(t) - nascido vivo",
  title = "KM - Nascido vivo (censura: óbito fetal) por tipo de parto",
  ggtheme = theme_minimal(base_size = 12)
)
```

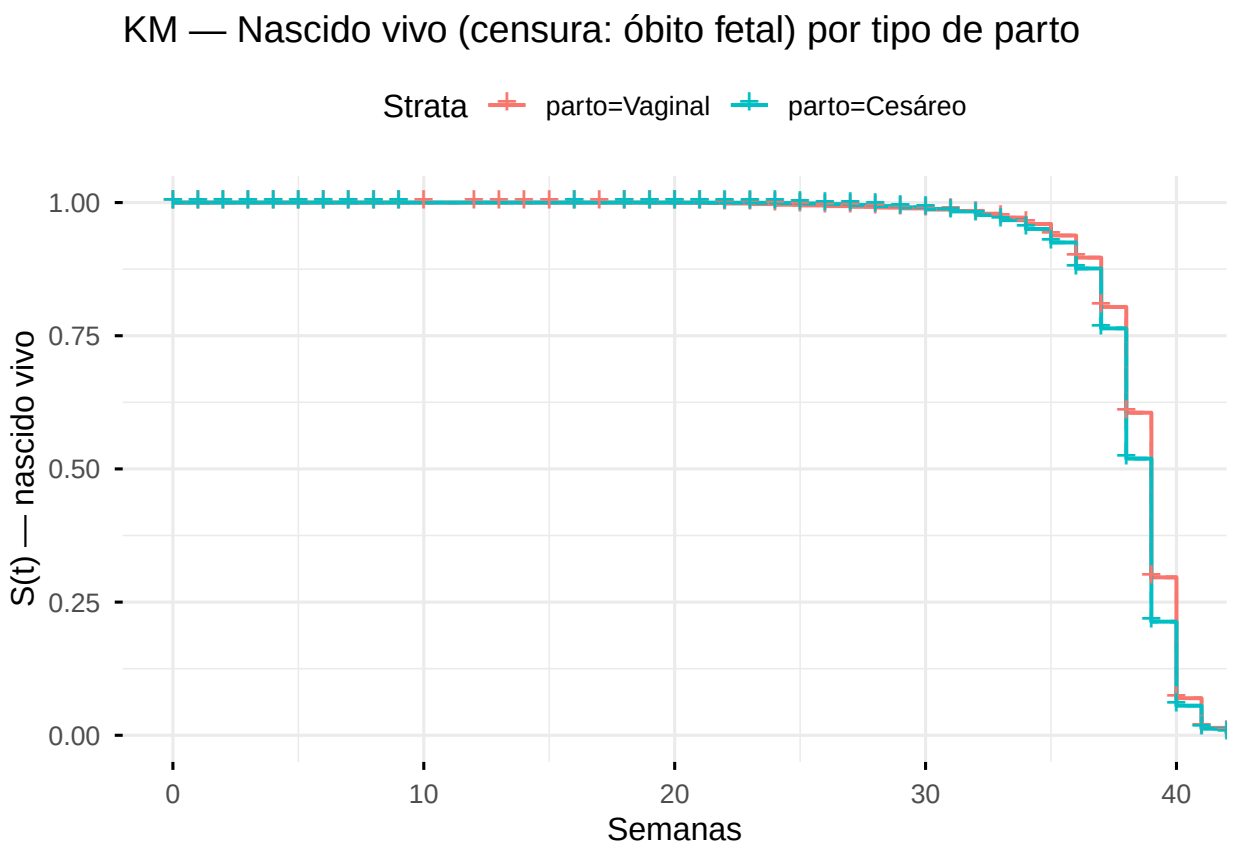


### Faixas de gestação

```
dados_eda <- dados_eda %>%
  dplyr::mutate(
    gestacao_fac = factor(
      gestacao,
      levels = c("1","2","3","4","5","6"),
      labels = c("<22","22-27","28-31","32-36","37-41"," 42")
    )
  )
dados_gest <- subset(dados_eda, !is.na(gestacao_fac))

# Óbito fetal como evento (censura = nascido vivo)
km_fd_gest <- survfit(Surv(tempo, status_fd) ~ gestacao_fac, data = dados_gest)
survminer::ggsurvplot(
  km_fd_gest, data = dados_gest, conf.int = TRUE,
  conf.int.style = "step",        # evita erro de ribbon
  linetype = 1, size = 0.7,       # fixa traço
  xlab = "Semanas", ylab = "S(t) - óbito fetal",
  title = "KM - Óbito fetal (censura: nascido vivo) por faixa de gestação",
  ggtheme = theme_minimal(base_size = 12),
  ylim = c(0.987, 1.00)           # zoom perto de 1
)
```

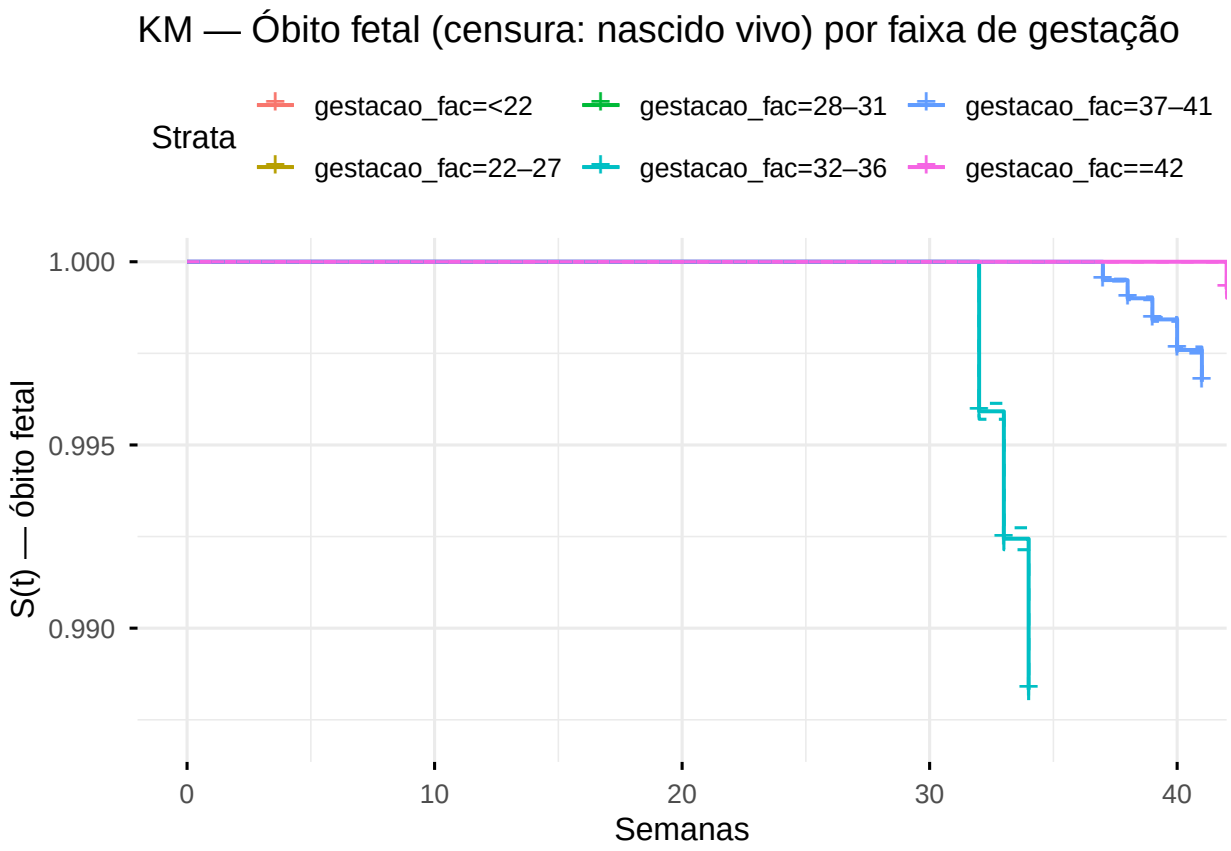


```r
# Nascido vivo como evento (óbito fetal censurado)
km_lv_gest <- survfit(Surv(tempo, status_lv) ~ gestacao_fac, data = dados_gest)
survminer::ggsurvplot(
  km_lv_gest, data = dados_gest, conf.int = TRUE,
  conf.int.style = "step",
  linetype = 1, size = 0.7,
  xlab = "Semanas", ylab = "S(t) - nascido vivo",
  title = "KM - Nascido vivo (censura: óbito fetal) por faixa de gestação",
  ggtheme = theme_minimal(base_size = 12)
)
```

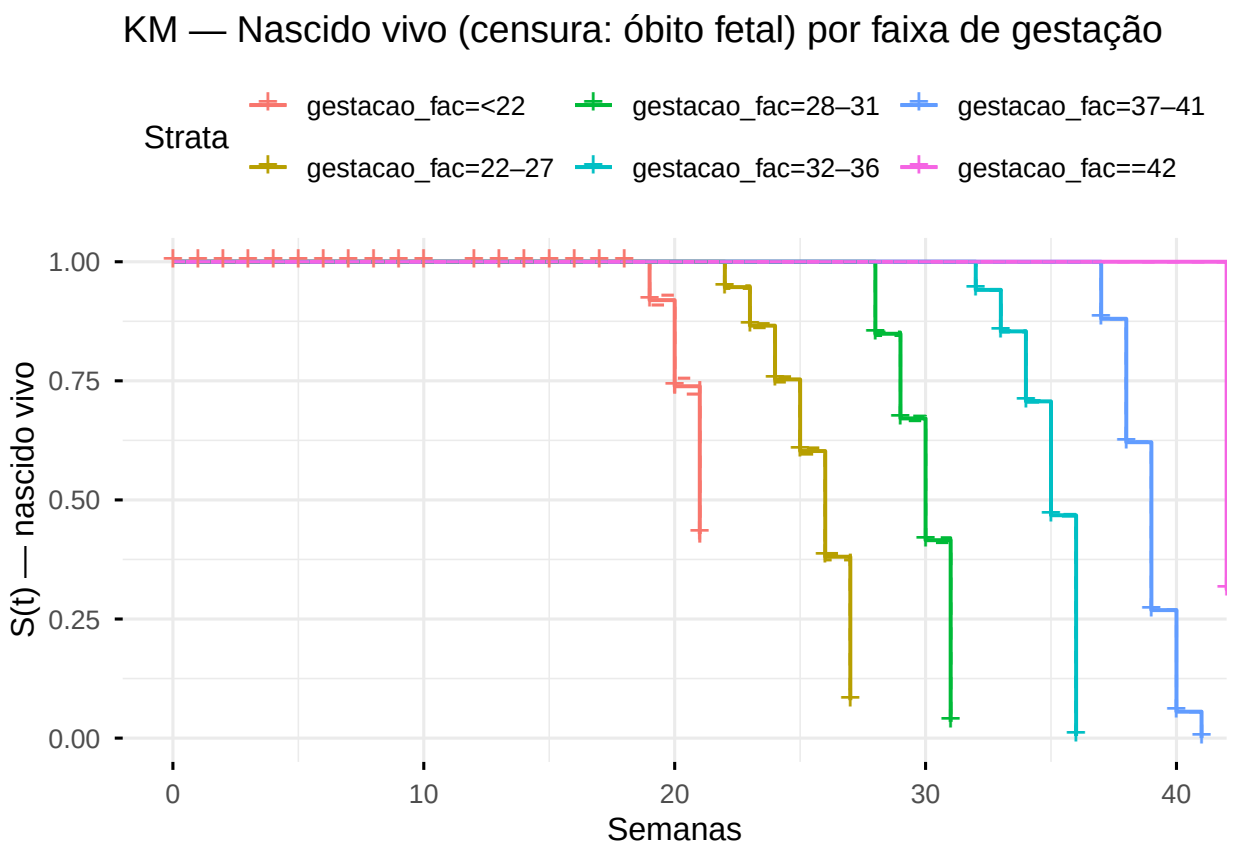


### escmae (escolaridade da mãe)

```
# Rotulagem explícita de escmae2010 conforme o dicionário oficial
dados_eda <- dados_eda %>%
  dplyr::mutate(
    escmae2010_lab = dplyr::case_when(
      is.na(escmae2010)                      ~ NA_character_,
      as.character(escmae2010) == "9"        ~ NA_character_,  # Ignorado -> NA
      as.character(escmae2010) == "0"        ~ "Sem escolaridade",
      as.character(escmae2010) == "1"        ~ "Fundamental 1 (1ª-4ª)",
      as.character(escmae2010) == "2"        ~ "Fundamental 2 (5ª-8ª)",
      as.character(escmae2010) == "3"        ~ "Médio (antigo 2º grau)",
      as.character(escmae2010) == "4"        ~ "Superior incompleto",
      as.character(escmae2010) == "5"        ~ "Superior completo",
      TRUE                                   ~ NA_character_
    ) %>% factor(levels = c("Sem escolaridade",
                            "Fundamental 1 (1ª-4ª)",
                            "Fundamental 2 (5ª-8ª)",
                            "Médio (antigo 2º grau)",
                            "Superior incompleto",
                            "Superior completo"),
                 ordered = TRUE)
  )

table(dados_eda$escmae2010_lab, useNA = "ifany")
```

```
##
##       Sem escolaridade  Fundamental 1 (1ª-4ª)  Fundamental 2 (5ª-8ª)
##                   3040                  40309                 430668
```

```
## Médio (antigo 2º grau)    Superior incompleto      Superior completo
##                 1910995                  168548                 731954
##                    <NA>
##                    9357
```

```
# Filtra casos com info necessária e com rótulo válido
dados_esc10 <- subset(dados_eda, !is.na(tempo) & !is.na(status_fd) & !is.na(escmae2010_lab))

# Óbito fetal como evento (censura = nascido vivo)
km_fd_esc10 <- survfit(Surv(tempo, status_fd) ~ escmae2010_lab, data = dados_esc10)

# rótulos na ordem exata das curvas
labs_fd <- sub("^.*=", "", names(km_fd_esc10$strata))

survminer::ggsurvplot(
  km_fd_esc10, data = dados_esc10, conf.int = TRUE,
  conf.int.style = "step", linetype = 1, size = 0.7,
  xlab = "Semanas", ylab = "S(t) - óbito fetal",
  title = "KM - Óbito fetal (censura: nascido vivo) por escolaridade (escmae2010)",
  ggtheme = theme_minimal(base_size = 12),
  ylim = c(0.95, 1.00),
  legend.title = NULL,     # sem título
  legend.labs  = labs_fd   # apenas o nome da categoria
)
```

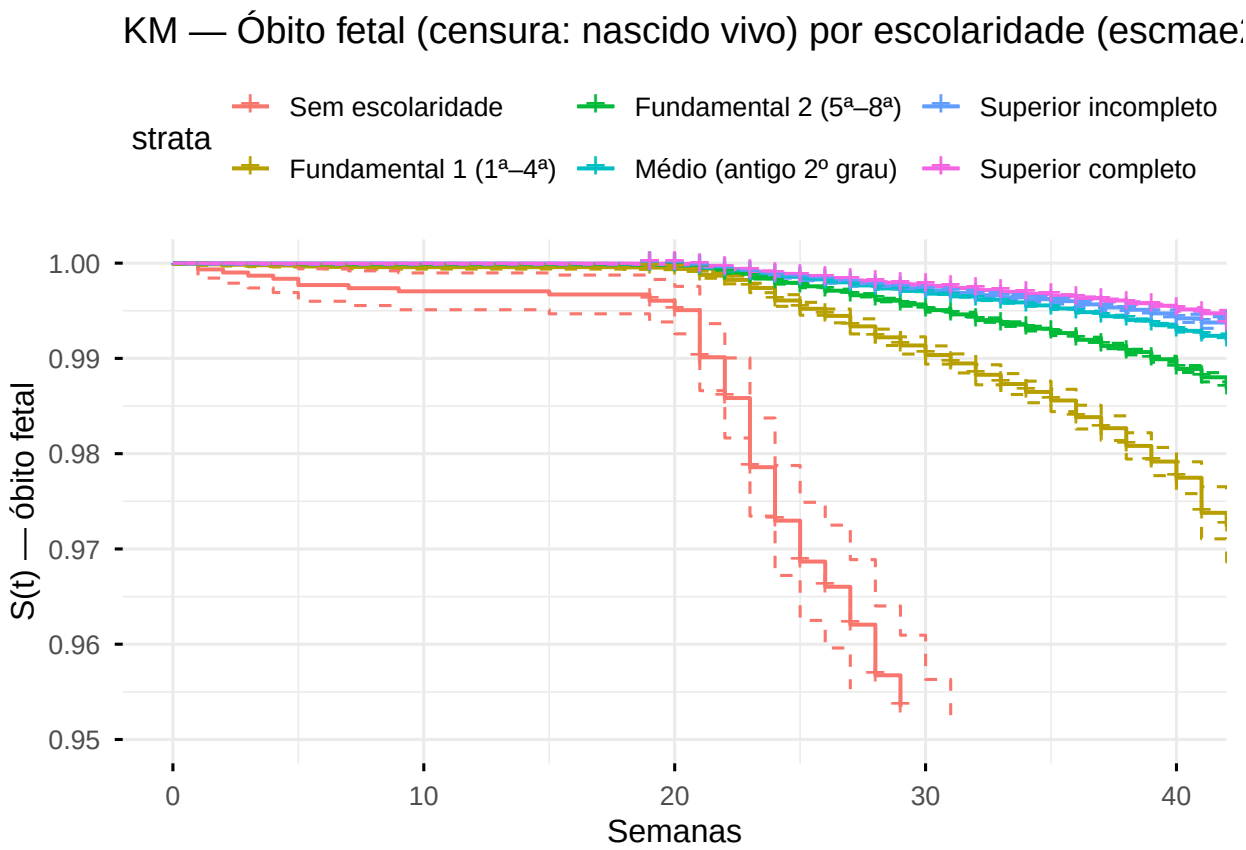


```
# Nascido vivo como evento (óbito fetal censurado)
km_lv_esc10 <- survfit(Surv(tempo, status_lv) ~ escmae2010_lab, data = dados_esc10)
```

```r
labs_lv <- sub("^.*=", "", names(km_lv_esc10$strata))

survminer::ggsurvplot(
  km_lv_esc10, data = dados_esc10, conf.int = TRUE,
  conf.int.style = "step", linetype = 1, size = 0.7,
  xlab = "Semanas", ylab = "S(t) - nascido vivo",
  title = "KM - Nascido vivo (censura: óbito fetal) por escolaridade (escmae2010)",
  ggtheme = theme_minimal(base_size = 12),
  legend.title = NULL,
  legend.labs  = labs_lv
)
```

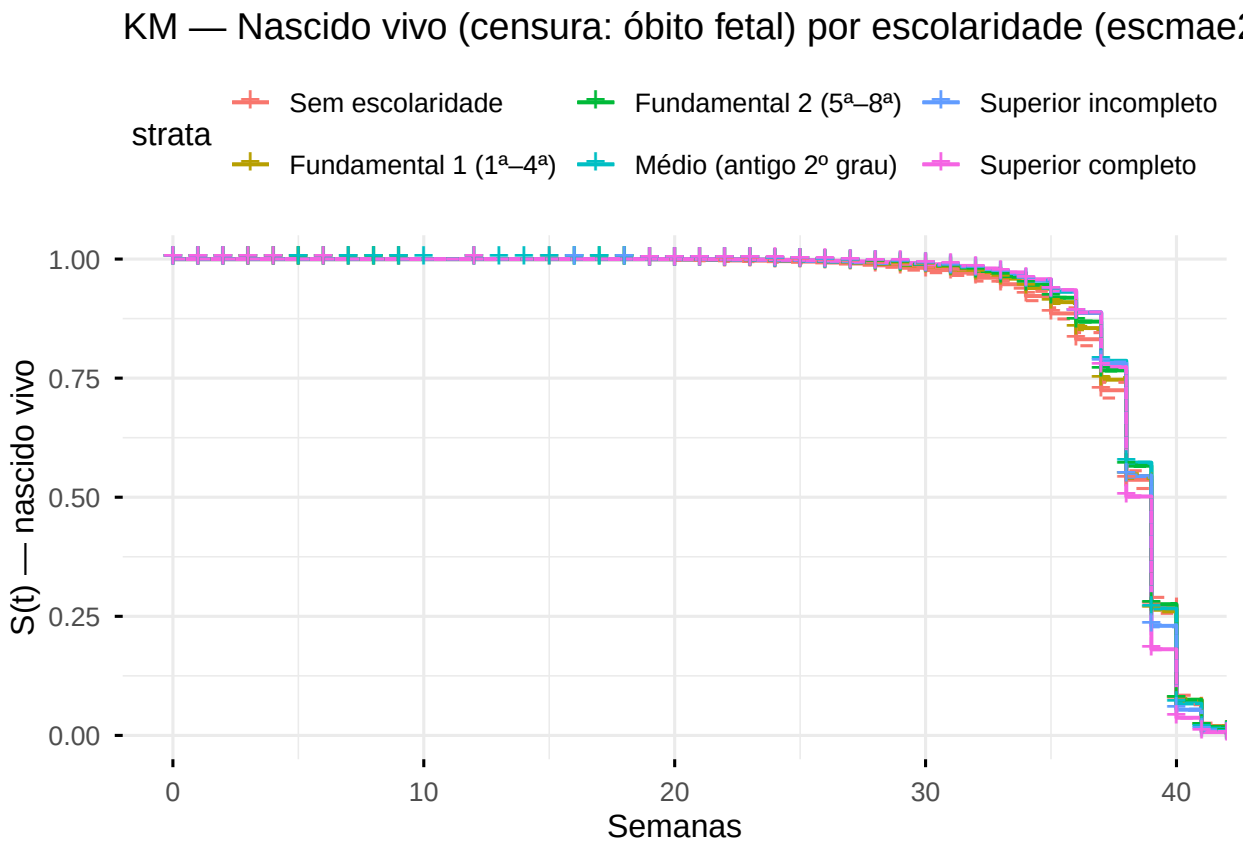


### Local de ocorrência

```r
# Padronizar a ordem dos níveis e remover NAs
dados_loc <- dados_eda %>%
  dplyr::mutate(
    lococornasc = forcats::fct_relevel(
      lococornasc,
      "Hospital", "Outros est. saúde", "Domicílio", "Via pública", "Outros",
      after = 0
    )
  ) %>%
  dplyr::filter(!is.na(tempo), !is.na(status_fd), !is.na(lococornasc))

# Óbito fetal como evento (censura = nascido vivo)
km_fd_loco <- survfit(Surv(tempo, status_fd) ~ lococornasc, data = dados_loc)
```

```r
# Legenda sem 'lococornasc='
labs_fd <- sub("^.*=", "", names(km_fd_loco$strata))

survminer::ggsurvplot(
  km_fd_loco, data = dados_loc, conf.int = TRUE,
  conf.int.style = "step", linetype = 1, size = 0.7,   # evita erro do ribbon
  xlab = "Semanas", ylab = "S(t) - óbito fetal",
  title = "KM - Óbito fetal (censura: nascido vivo) por local de ocorrência/nasc",
  ggtheme = theme_minimal(base_size = 12),
  ylim = c(0.987, 1.00),
  legend.title = NULL,
  legend.labs  = labs_fd
)
```

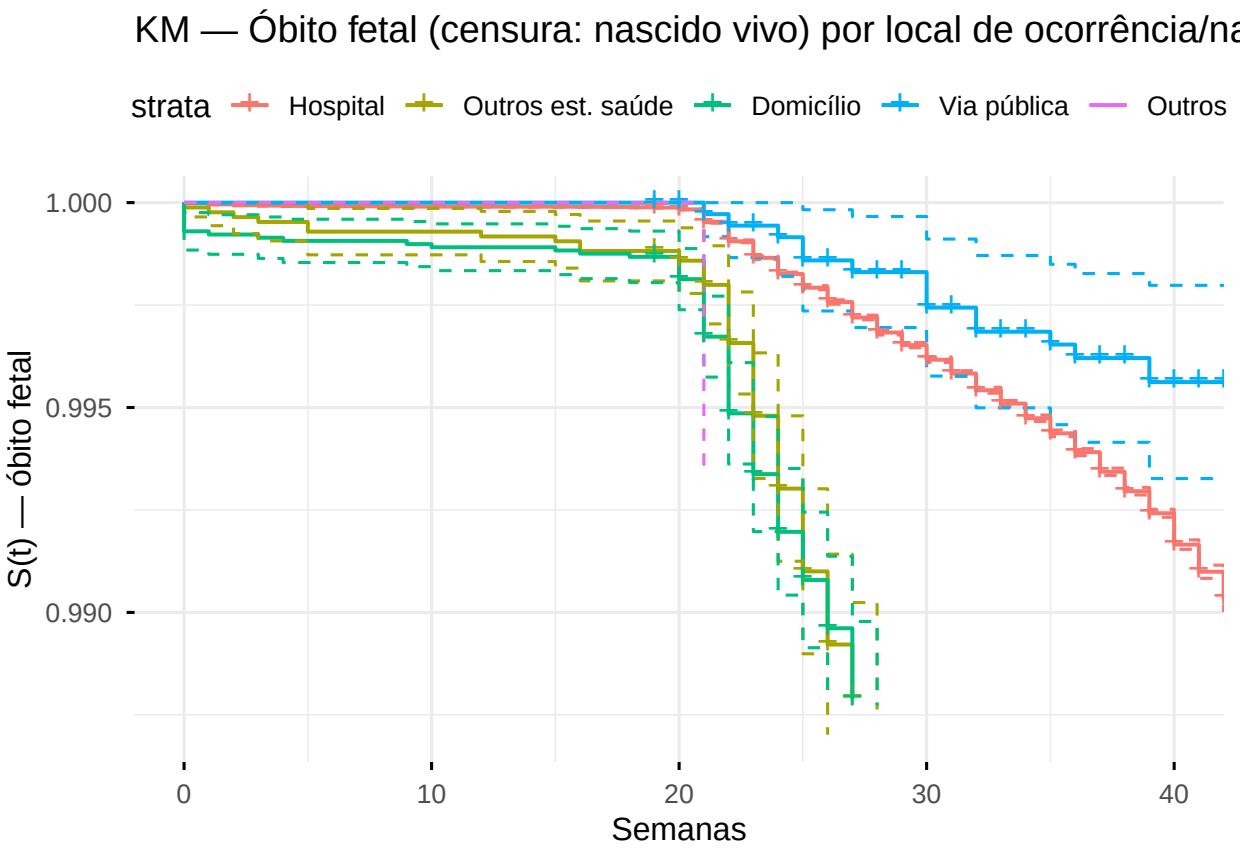


```r
# Nascido vivo como evento (óbito fetal censurado)
dados_loc_lv <- dplyr::filter(dados_eda, !is.na(tempo), !is.na(status_lv), !is.na(lococornasc))
km_lv_loco <- survfit(Surv(tempo, status_lv) ~ lococornasc, data = dados_loc_lv)

labs_lv <- sub("^.*=", "", names(km_lv_loco$strata))

survminer::ggsurvplot(
  km_lv_loco, data = dados_loc_lv, conf.int = TRUE,
  conf.int.style = "step", linetype = 1, size = 0.7,
  xlab = "Semanas", ylab = "S(t) - nascido vivo",
  title = "KM - Nascido vivo (censura: óbito fetal) por local de ocorrência/nasc",
  ggtheme = theme_minimal(base_size = 12),
  legend.title = NULL,
```

```
  legend.labs  = labs_lv
)
```

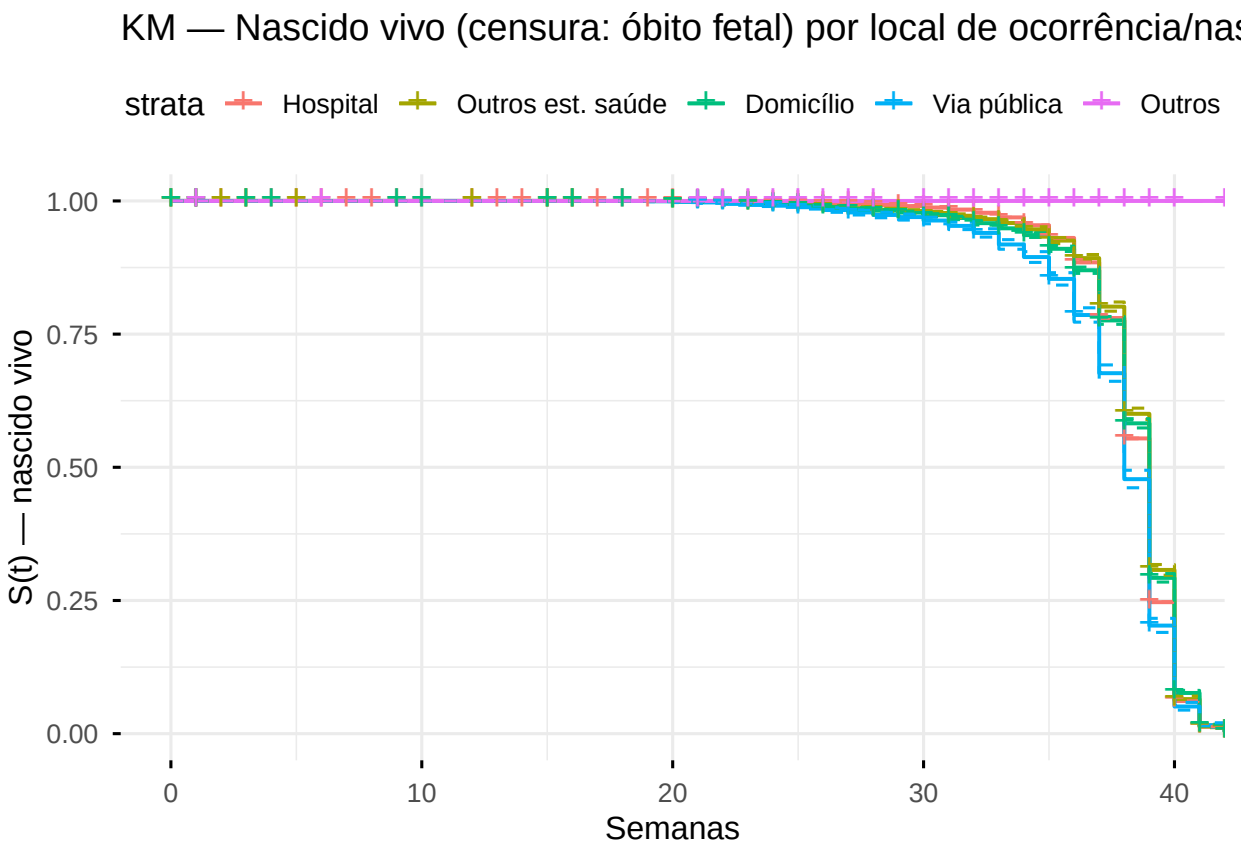


### Tipo de gravidez (níveis originais)

```
# Ordena níveis e remove NAs antes de ajustar
dados_grav <- dados_eda %>%
  dplyr::mutate(
    gravidez = forcats::fct_relevel(gravidez, "Única", "Dupla", "Tripla ou mais")
  ) %>%
  dplyr::filter(!is.na(tempo), !is.na(gravidez), !is.na(status_fd))

# Óbito fetal como evento (censura = nascido vivo)
km_fd_grav <- survfit(Surv(tempo, status_fd) ~ gravidez, data = dados_grav)
labs_fd <- sub("^.*=", "", names(km_fd_grav$strata))  # remove "gravidez=" da legenda

survminer::ggsurvplot(
  km_fd_grav, data = dados_grav, conf.int = TRUE,
  conf.int.style = "step", linetype = 1, size = 0.7,
  xlab = "Semanas", ylab = "S(t) - óbito fetal",
  title = "KM - Óbito fetal (censura: nascido vivo) por tipo de gravidez",
  ggtheme = theme_minimal(base_size = 12),
  ylim = c(0.987, 1.00),
  legend.title = NULL, legend.labs = labs_fd
)
```

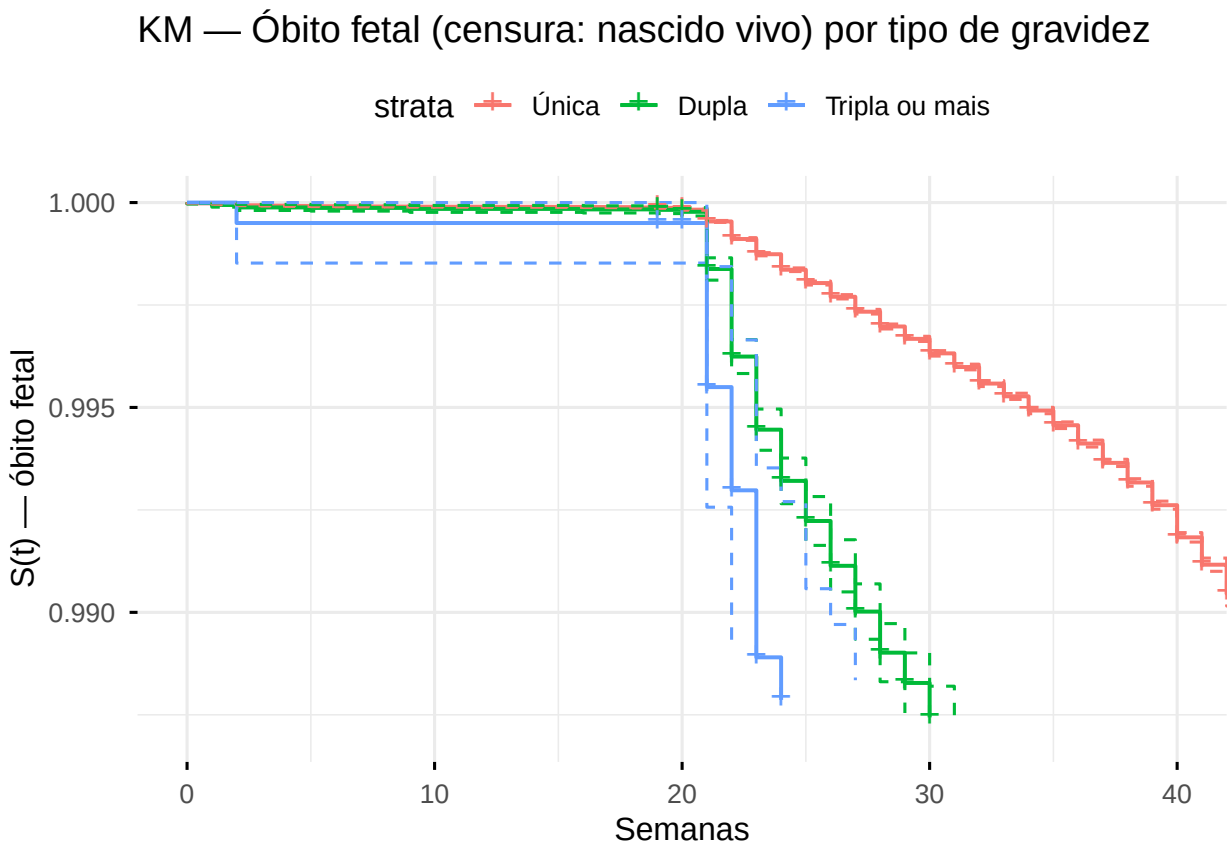


```r
# Nascido vivo como evento (censura = óbito fetal)
dados_grav_lv <- dplyr::filter(dados_eda, !is.na(tempo), !is.na(gravidez), !is.na(status_lv))
km_lv_grav <- survfit(Surv(tempo, status_lv) ~ gravidez, data = dados_grav_lv)
labs_lv <- sub("^.*=", "", names(km_lv_grav$strata))

survminer::ggsurvplot(
  km_lv_grav, data = dados_grav_lv, conf.int = TRUE,
  conf.int.style = "step", linetype = 1, size = 0.7,
  xlab = "Semanas", ylab = "S(t) - nascido vivo",
  title = "KM - Nascido vivo (censura: óbito fetal) por tipo de gravidez",
  ggtheme = theme_minimal(base_size = 12),
  legend.title = NULL, legend.labs = labs_lv
)
```

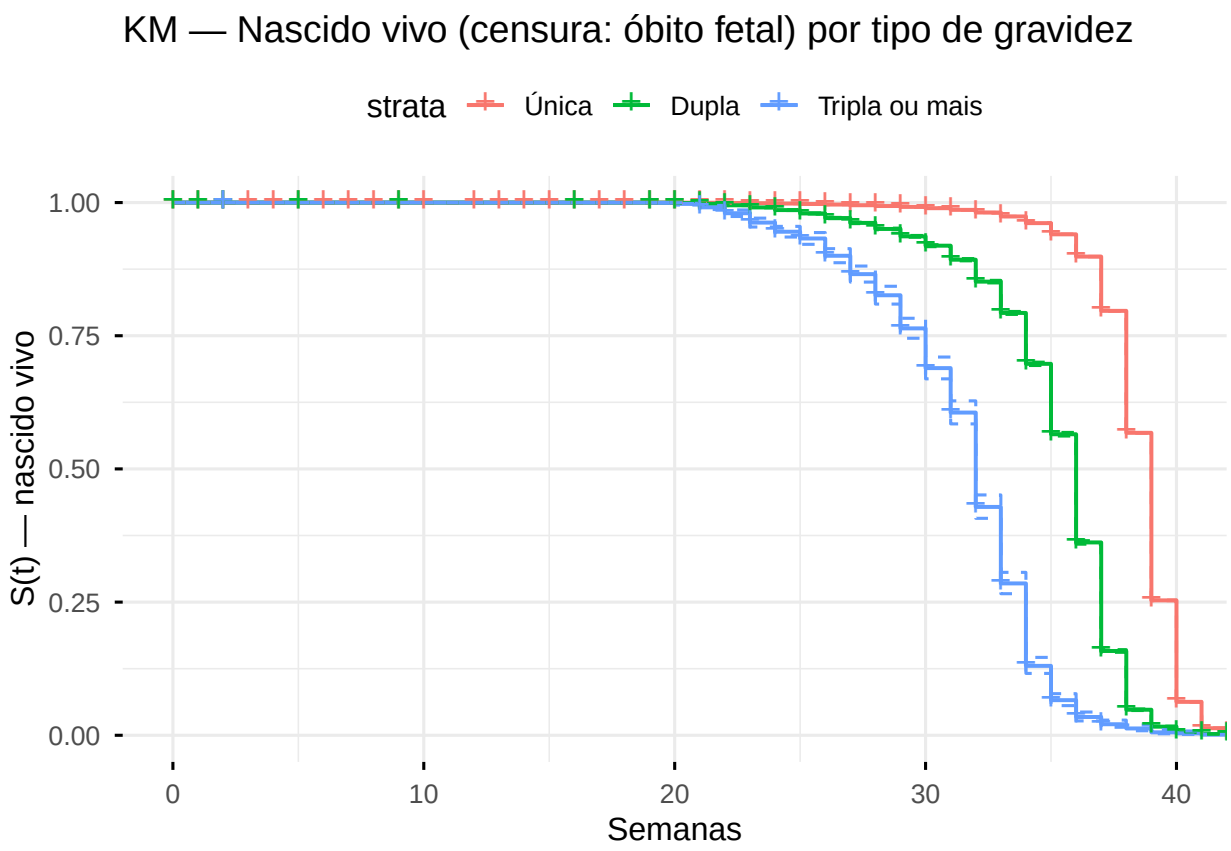


### Tipo de gravidez (Única vs Múltipla)

```
# Cria variável binária rotulada
dados_eda <- dados_eda %>%
  dplyr::mutate(
    gravidez_bin = dplyr::case_when(
      is.na(gravidez)                        ~ NA_character_,
      gravidez == "Única"                    ~ "Única",
      gravidez %in% c("Dupla","Tripla ou mais") ~ "Múltipla",
      TRUE                                   ~ NA_character_
    ) %>% forcats::fct_relevel("Única","Múltipla")
  )

# Filtra dados válidos
dados_grav2_fd <- dplyr::filter(dados_eda, !is.na(tempo), !is.na(status_fd), !is.na(gravidez_bin))
dados_grav2_lv <- dplyr::filter(dados_eda, !is.na(tempo), !is.na(status_lv), !is.na(gravidez_bin))

# Óbito fetal como evento (censura = nascido vivo)
km_fd_grav2 <- survfit(Surv(tempo, status_fd) ~ gravidez_bin, data = dados_grav2_fd)
labs_fd2 <- sub("^.*=", "", names(km_fd_grav2$strata))

survminer::ggsurvplot(
  km_fd_grav2, data = dados_grav2_fd, conf.int = TRUE,
  conf.int.style = "step", linetype = 1, size = 0.7,
  xlab = "Semanas", ylab = "S(t) - óbito fetal",
  title = "KM - Óbito fetal (censura: nascido vivo) gravidez (Única x Múltipla)",
  ggtheme = theme_minimal(base_size = 12),
  ylim = c(0.987, 1.00),
```

```
  legend.title = NULL, legend.labs = labs_fd2
)
```

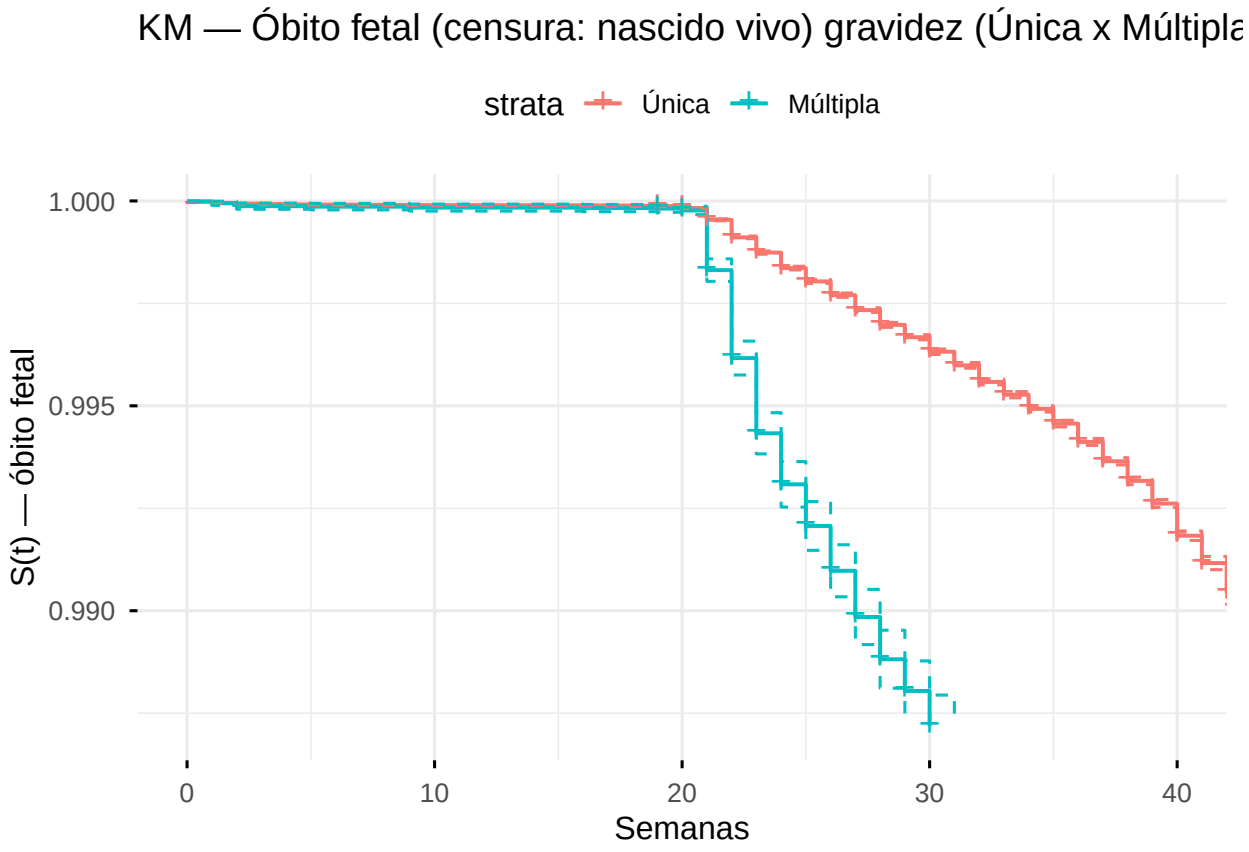


```
# Nascido vivo como evento (óbito fetal censurado)
km_lv_grav2 <- survfit(Surv(tempo, status_lv) ~ gravidez_bin, data = dados_grav2_lv)
labs_lv2 <- sub("^.*=", "", names(km_lv_grav2$strata))

survminer::ggsurvplot(
  km_lv_grav2, data = dados_grav2_lv, conf.int = TRUE,
  conf.int.style = "step", linetype = 1, size = 0.7,
  xlab = "Semanas", ylab = "S(t) - nascido vivo",
  title = "KM - Nascido vivo (censura: óbito fetal) gravidez (Única x Múltipla)",
  ggtheme = theme_minimal(base_size = 12),
  legend.title = NULL, legend.labs = labs_lv2
)
```

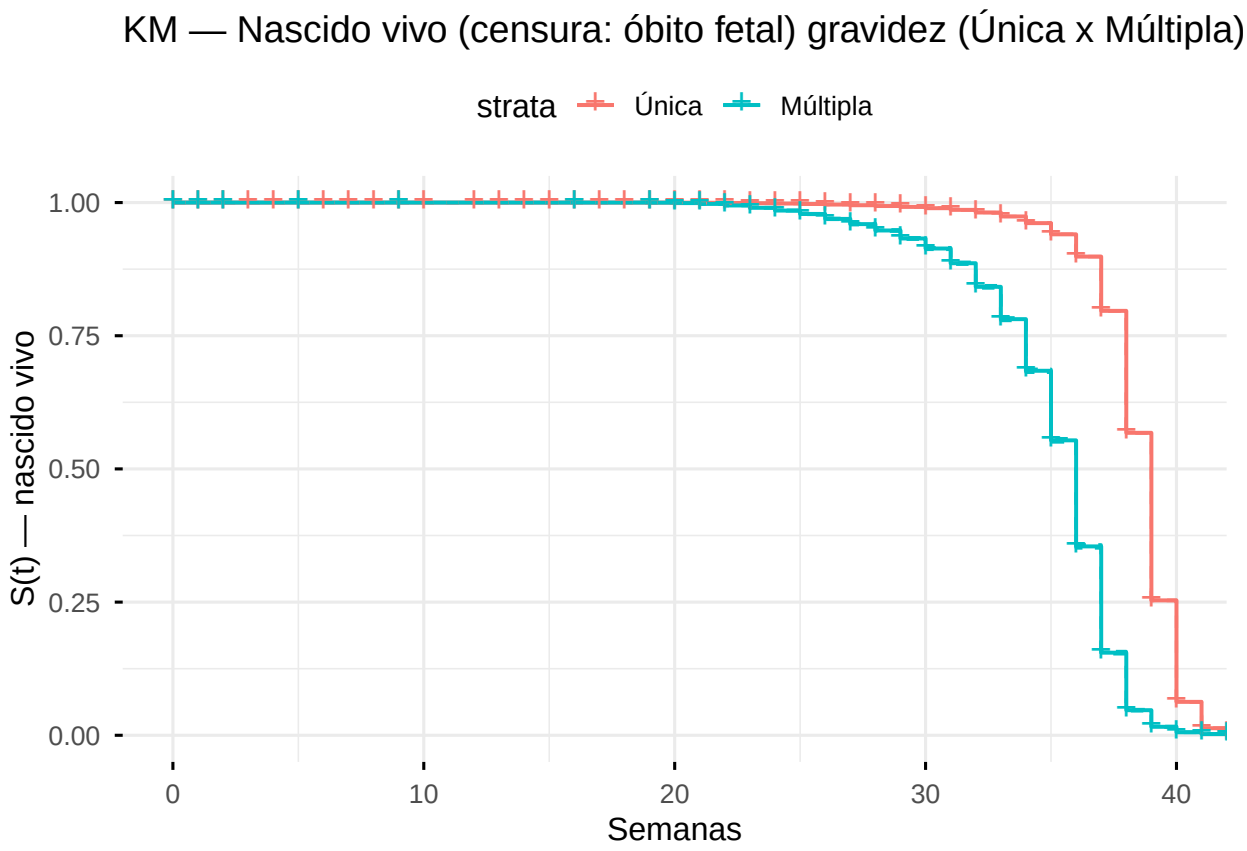


**qtdfilvivo (Número de filhos vivos) e qtdfilmort (Número de filhos mortos)**

```
dados_eda <- dados_eda %>%
  dplyr::mutate(
    # filhos vivos anteriores
    qtdfilvivo_n = suppressWarnings(as.integer(qtdfilvivo)),
    # trata valores muito altos como NA (15 +)
    qtdfilvivo_n = ifelse(qtdfilvivo_n > 15, NA_integer_, qtdfilvivo_n),
    qtdfilvivo_cat = dplyr::case_when(
      is.na(qtdfilvivo_n)      ~ NA_character_,
      # Categorias escolhidas de forma arbitrária para exploração
      #(verificar se faz sentido)
      qtdfilvivo_n == 0        ~ "0",
      qtdfilvivo_n %in% 1:2    ~ "1-2",
      qtdfilvivo_n %in% 3:4    ~ "3-4",
      qtdfilvivo_n >= 5        ~ " 5"
    ) %>% factor(levels = c("0","1-2","3-4"," 5")),

    # filhos mortos anteriores
    qtdfilmort_n = suppressWarnings(as.integer(qtdfilmort)),
    qtdfilmort_n = ifelse(qtdfilmort_n > 10, NA_integer_, qtdfilmort_n),
    qtdfilmort_cat = dplyr::case_when(
      is.na(qtdfilmort_n)      ~ NA_character_,
      # Categorias escolhidas de forma arbitrária para exploração
      #(verificar se faz sentido)
      qtdfilmort_n == 0        ~ "0",
      qtdfilmort_n == 1        ~ "1",
      qtdfilmort_n >= 2        ~ " 2"
```

```r
    ) %>% factor(levels = c("0","1","2"))
  )

table(dados_eda$qtdfilvivo_cat, useNA = "ifany")
```

```
##
##       0     1-2     3-4       5    <NA>
## 1446495 1562589  239689   46090       8
```

```r
table(dados_eda$qtdfilmort_cat, useNA = "ifany")
```

```
##
##       0       1       2    <NA>
## 2624852  531178  138752      89
```

```r
# Filtrar registros com info necessária
dd_vivo_fd <- subset(dados_eda, !is.na(tempo) & !is.na(status_fd) & !is.na(qtdfilvivo_cat))
dd_vivo_lv <- subset(dados_eda, !is.na(tempo) & !is.na(status_lv) & !is.na(qtdfilvivo_cat))

# Óbito fetal como evento (nascido vivo censurado)
km_fd_qv <- survfit(Surv(tempo, status_fd) ~ qtdfilvivo_cat, data = dd_vivo_fd)
labs_fd_qv <- sub("^.*=", "", names(km_fd_qv$strata))

survminer::ggsurvplot(
  km_fd_qv, data = dd_vivo_fd, conf.int = TRUE,
  conf.int.style = "step", linetype = 1, size = 0.7,
  xlab = "Semanas", ylab = "S(t) - óbito fetal",
  title = "KM - Óbito fetal (censura: nascido vivo) por nº de filhos vivos prévios",
  ggtheme = theme_minimal(base_size = 12),
  ylim = c(0.987, 1.00),
  legend.title = NULL, legend.labs = labs_fd_qv
)
```

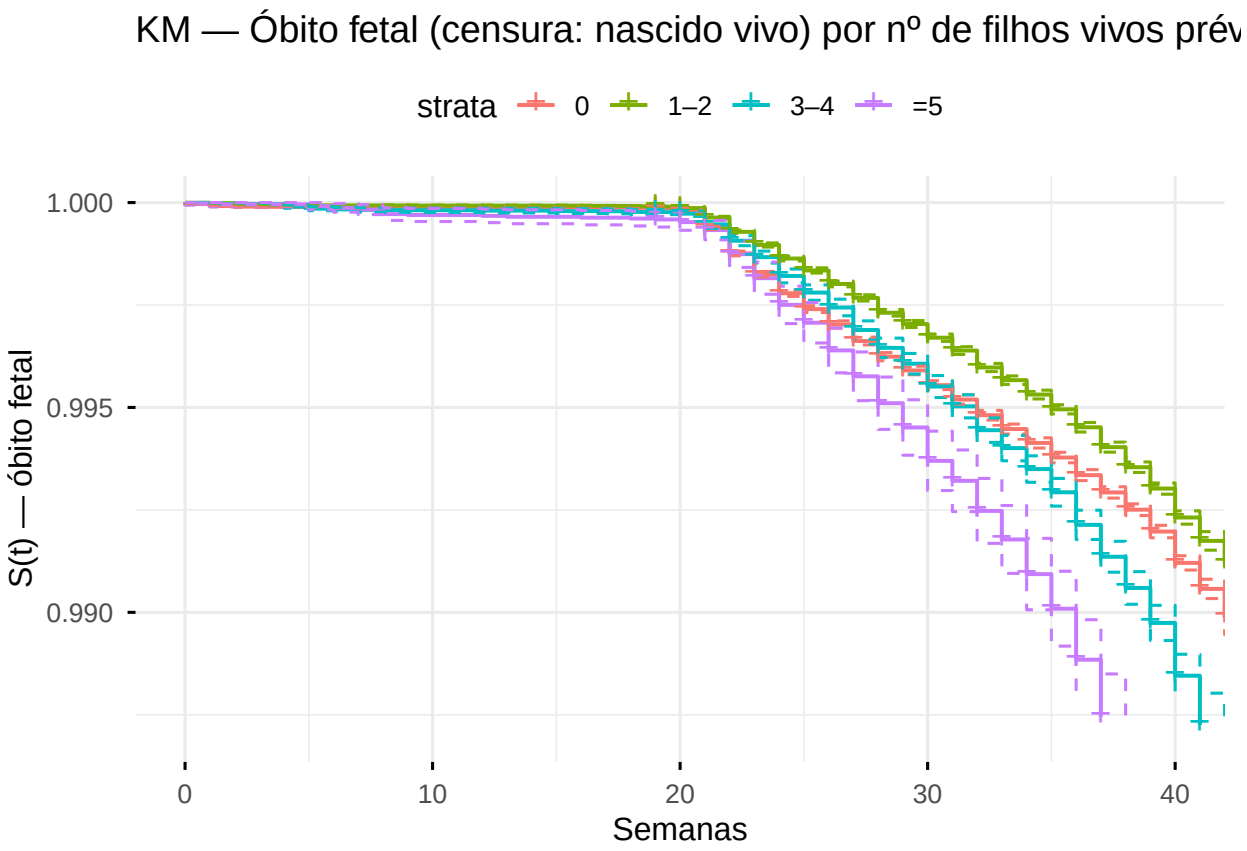


```r
# Nascido vivo como evento (óbito fetal censurado)
km_lv_qv <- survfit(Surv(tempo, status_lv) ~ qtdfilvivo_cat, data = dd_vivo_lv)
labs_lv_qv <- sub("^.*=", "", names(km_lv_qv$strata))

survminer::ggsurvplot(
  km_lv_qv, data = dd_vivo_lv, conf.int = TRUE,
  conf.int.style = "step", linetype = 1, size = 0.7,
  xlab = "Semanas", ylab = "S(t) - nascido vivo",
  title = "KM - Nascido vivo (censura: óbito fetal) por nº de filhos vivos prévios",
  ggtheme = theme_minimal(base_size = 12),
  legend.title = NULL, legend.labs = labs_lv_qv
)
```

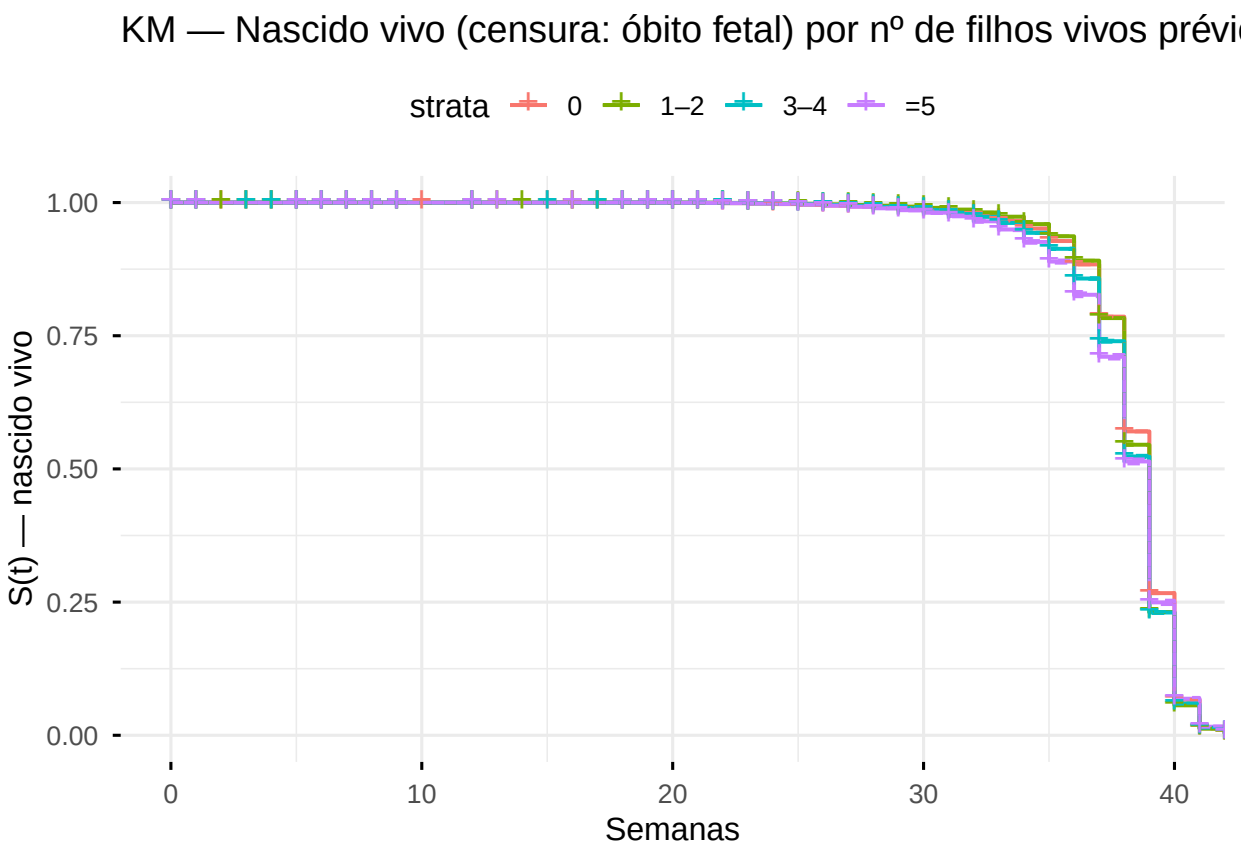


```r
# Filtrar registros com info necessária
dd_mort_fd <- subset(dados_eda, !is.na(tempo) & !is.na(status_fd) & !is.na(qtdfilmort_cat))
dd_mort_lv <- subset(dados_eda, !is.na(tempo) & !is.na(status_lv) & !is.na(qtdfilmort_cat))

# Óbito fetal como evento (nascido vivo censurado)
km_fd_qm <- survfit(Surv(tempo, status_fd) ~ qtdfilmort_cat, data = dd_mort_fd)
labs_fd_qm <- sub("^.*=", "", names(km_fd_qm$strata))

survminer::ggsurvplot(
  km_fd_qm, data = dd_mort_fd, conf.int = TRUE,
  conf.int.style = "step", linetype = 1, size = 0.7,
  xlab = "Semanas", ylab = "S(t) - óbito fetal",
  title = "KM - Óbito fetal (censura: nascido vivo) por nº de filhos mortos prévios",
  ggtheme = theme_minimal(base_size = 12),
  ylim = c(0.987, 1.00),
  legend.title = NULL, legend.labs = labs_fd_qm
)
```

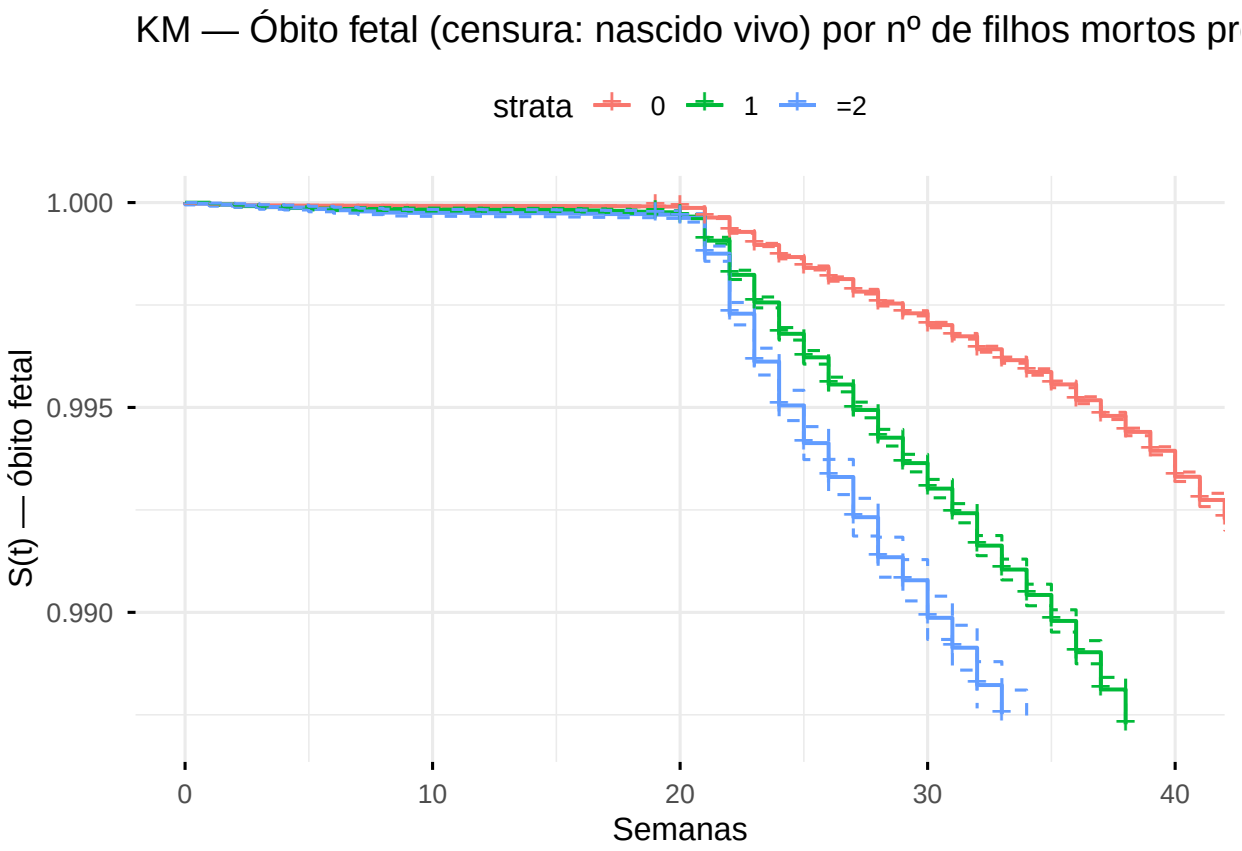


```r
# Nascido vivo como evento (óbito fetal censurado)
km_lv_qm <- survfit(Surv(tempo, status_lv) ~ qtdfilmort_cat, data = dd_mort_lv)
labs_lv_qm <- sub("^.*=", "", names(km_lv_qm$strata))

survminer::ggsurvplot(
  km_lv_qm, data = dd_mort_lv, conf.int = TRUE,
  conf.int.style = "step", linetype = 1, size = 0.7,
  xlab = "Semanas", ylab = "S(t) - nascido vivo",
  title = "KM - Nascido vivo (censura: óbito fetal) por nº de filhos mortos prévios",
  ggtheme = theme_minimal(base_size = 12),
  legend.title = NULL, legend.labs = labs_lv_qm
)
```

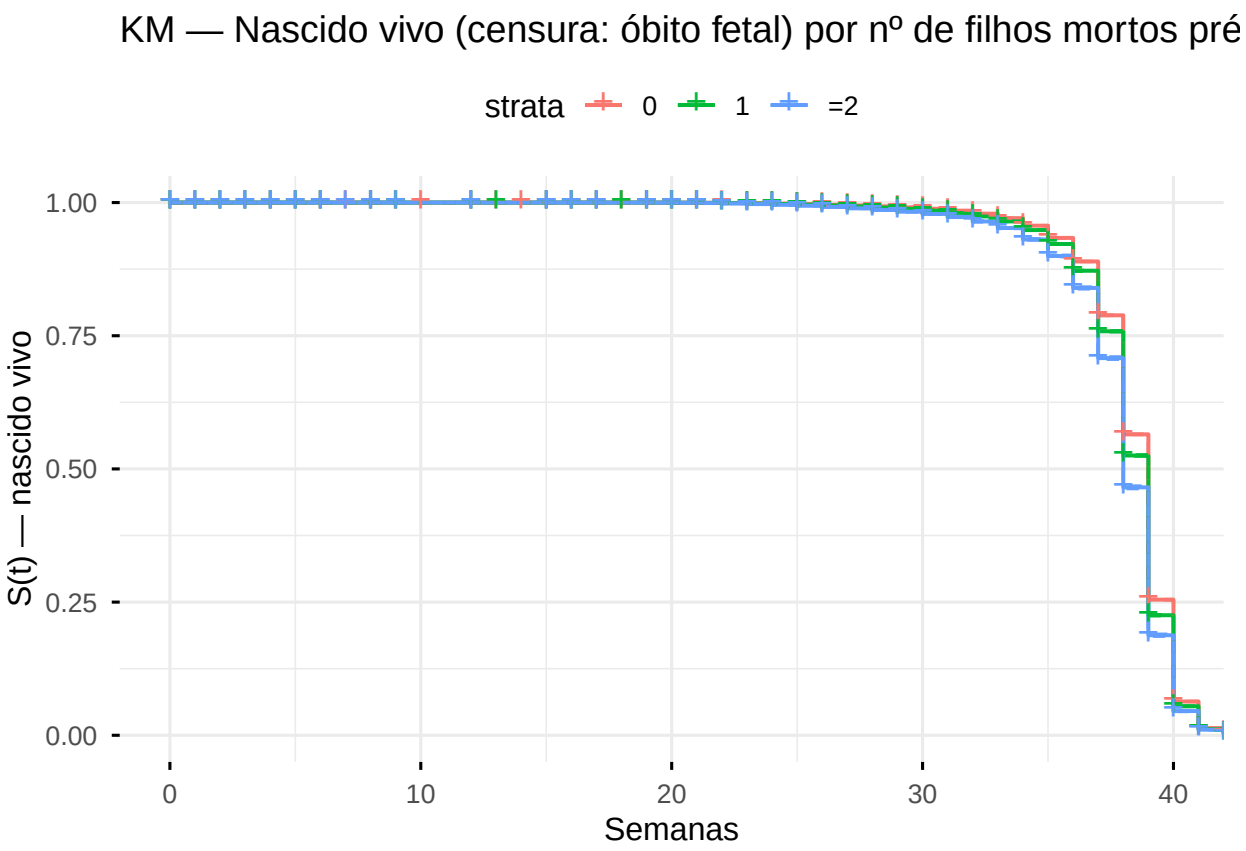


## Comentários

De acordo com o manual de instruções para preenchimento de declaração de óbito Link:Manual de preenchimento:

- Condições para emissão da Declaração de Óbito.
  - Óbito fetal, de acordo com os seguintes critérios: gestação com duração igual ou superior a 20 semanas OU feto com peso corporal igual ou superior a 500 g OU estatura igual ou superior a 25 cm.
  - A DO não deve ser emitida se a gestação teve duração menor que 20 semanas E se o feto tiver peso corporal menor que 500 g E estatura menor que 25 cm

Porém como mencionado em Link:

O Centro Nacional de Estatística da Saúde dos Estados Unidos conceitua morte fetal aquela ocorrida a partir de 20 semanas de gestação. Da mesma forma, para acomodar os interesses burocráticos, a maioria das estatísticas nacionais sobre o assunto preferem defini-lo a partir de 20 semanas de gestação ou peso no nascimento maior que 500 gramas.

Após já ter visto os gráficos de kaplan-meier feitos posteriormente, foi possível notar que a queda da curva em praticamente todas as variáveis apenas ocorre após a semana gestacional 20, então, para evitar a longa calda à esquerda e ter uma melhor visualização dos gráficos, talvez vale considerar semana gestacional acima de 20.